

Modelado predictivo del riesgo diario de incendio

Bloque de aprendizaje automatico

1 Datos

Nueve fuentes heterogeneas convertidas en una fila de 46 variables por celda y dia. Lo que cambia entre las dos iteraciones del trabajo no son los datos: es que se toma como positivo, que como negativo y que como verdad.

Fuente	Que aporta	Detalle
IberFire (cubo)	45 de las 46 variables	NetCDF de 30,3 GB, 261 variables, EPSG:3035, 1.188×920 celdas de 1 km (498.530 peninsulares), 2007–2024. Tekniker/UPV-EHU, arXiv:2505.00837, CC-BY 4.0
EGIF (Civio)	Etiqueta de la iteracion 1	19.561 igniciones 2015–2020 con coordenadas, punto y no perimetro. <i>Incompleto desde 2021</i> (888/226/23 registros): fija la ventana temporal
EFFIS	Etiqueta de la iteracion 2 y juez	Celda quemada ≥ 5 ha, diaria. Ciego a lo pequeno; situa el fuego en el perimetro
ERA5-Land	La meteorologia al servir	~9 km sobre 5.605 nodos, mas prevision IFS para D y D+1. Al entrenar entra via cubo
FIRMS (VIIRS)	2 variables de entorno	~256.000 detecciones 2015–24, ventana [D–7, D–1] y radio 50 km. Nunca el dia D: seria circular
WGLC, AEMET, MITECO, extra	Rayos, meteo del prototipo, juez D+1, carreteras y ganaderia	

Tabla 1: Las fuentes y su papel. Fichas completas en docs/FUENTES_DATOS_DETALLE.md.

Dentro del cubo, la meteorologia es ERA5-Land remuestreado a 1 km por vecino mas proximo; la vegetacion, Copernicus CLMS; el terreno, EU-DEM; el uso del suelo, CORINE. **Dos avisos condicionan todo lo demas:** el FWI del cubo son **las 13 UTC** (servirlo a otra hora introduce un factor ~ 2), y **ERA5-Land llueve de mas** —+8,00 mm en 30 dias frente a AEMET—, de donde se propaga un FWI diez puntos mas bajo. Por eso entrenar y servir con la misma fuente importa tanto.

2 Analisis exploratorio

Cada resultado de este capitulo justifica una decision posterior, y uno de ellos anticipa el problema entero del trabajo.

Las dos etiquetas no son la misma cosa. Solo el 2,6 % de los incendios EGIF de 5–25 ha tienen `is_fire=1` ese dia en su celda; el 34 % de los de 100–500 ha y el 59 % de los de >500 ha. Y su estacionalidad difiere: en EGIF **el 38 % del ano va de febrero a abril**, mientras EFFIS se concentra en julio y agosto → *justifica no entrenar solo con verano*. La causa es humana en el **97 %** (intencionado 68 %, negligencia 12 %, rayo 2,4 %): la cota superior honesta de cualquier modelo meteorologico.

La prevalencia real es el numero que lo cambia todo. Celdas-dia con fuego por 100.000 sobre las 498.530 celdas: 0,40 en 2018, 3,08 en 2020, **14,16 en 2022**, 1,82 en 2024 —es decir, **2–6 por 100.000 en un verano normal frente al 25 % de positivos que el conjunto de la iteracion 1 tiene por construccion: cinco ordenes de magnitud**. Medido en el capitulo 2 y no en el 5: el analisis exploratorio ya contenia el diagnostico que costo un ciclo entero entender. El fuego ademas se concentra: solo el 2,97 % de las celdas tuvo alguna ignicion en 2015–20.

La etiqueta persiste y la senal esta autocorrelada. $P(\text{fuego en } t+1 \mid \text{fuego en } t) = 0,51$; a los 7 dias 0,04. `is_fire` marca dias ardiendo, no igniciones → la evaluacion usa `primer_dia`. Moran’s I del EFFIS por celda es **0,81** a 1 km (perimetros contiguos del mismo fuego), y **partir al azar en vez de por bloques de 100 km infla el AUC en +0,036** → ninguna particion del trabajo es aleatoria.

Un mapa estatico ya llega lejos. Un XGBoost por celda, sin mirar el dia, alcanza AUC **0,82–0,84** y su decil superior concentra el **54–60 %** de las igniciones del ano. Cualquier modelo que no contenga esa informacion parte perdiendo.

Y las estaticas no separan nada. En el *train* de la iteracion 1, la mediana de `popdens` es **9,67 en positivos y 9,67 en negativos**; la de `dist_carreteras`, 0,63 y 0,63. No es un defecto de los datos: es aritmetica del diseno. Con pseudo-ausencias tomadas de la misma celda, las variables de la celda son identicas a los dos lados y *no pueden* discriminar. Lo que si separa es el peligro relativo: `fwi_pct1_local` 84,33 frente a 47,00.

► **Figuras 2.1–2.4** — ciclo anual; distribuciones por clase; correlaciones; normalizacion local. Ya generadas en [02_edo/figuras/](#).

3 Variables e ingeniería

Las 46 variables se reparten en meteorología y peligro (21), vegetación (4), estáticas de la celda (12), historial de fuego (5), fuego activo y rayos (4) y calendario (4).

Las ventanas móviles son 7, 15 y 30 días, y todas son $[D-w, D-1]$, excluyendo el día D : regla anti-fuga sin excepción. A 7 días, `precip_7d`, `fwi_med_7d`, `fwi_max_7d` y las medias de `rh_min`, `t2m_max` y `viento_max`; a 15, `precip_15d` y `fwi_med_15d`; a 30, `precip_30d`, `fwi_med_30d` y `ndvi_med_30d`. El combustible tiene memoria, y las ventanas son las que la capturan. Se derivan además `vpd_max` (Magnus, sobre `t2m_max` y `rh_min`) y `dias_sin_lluvia` (racha con precipitación <1 mm, tope 120).

La normalización local del peligro es la aportación propia. Un FWI de 15 es “moderado” en la escala EFFIS, pero en Galicia (mediano 3–14) es un día excepcionalmente seco y en el Mediterráneo (38–41) uno normal de mayo: el umbral fijo **penaliza a las zonas húmedas**, que son justo donde más arde. Con una climatología del FWI por (celda, mes) calculada **solo con 2008–2014** —anterior al conjunto, sin fuga— se derivan `fwi_pctl_local` y `fwi_anom_sigma`. Las comunidades atlánticas arden con FWI absoluto 3–14 y las mediterráneas con 38–41, pero **el percentil local converge a 73–92 en todas**.

Modelo (test 2020, prevalencia 26,28 %)	AUC-PR	AUC-ROC	n
A — FWI absoluto como <i>score</i> , sin ML	0,488	0,729	1
B — XGBoost solo-FWI	0,491	0,736	1
C — XGBoost meteo + FWI (con ventanas)	0,716	0,882	21
D — XGBoost completo	0,843	0,931	50

Tabla 2: Escalera de líneas base: cada peldano de complejidad, justificado con su medida.

El salto grande no es del FWI al aprendizaje automático (B apenas mejora sobre A): es de meteorología puntual a meteorología con ventanas (+0,23), y de ahí a incorporar historial, estáticas y calendario (+0,13). Tres ablaciones que conviene reportar por honestidad: el calendario solo (mes, día del año, festivo, comunidad) ya da 0,476 —*parte del rendimiento es “cuando y donde”, no física de combustible*—; calendario más FWI local alcanza el 89 % del AUC-PR completo con seis columnas; y combinar FWI absoluto y local (0,710) rinde **+0,042** sobre el absoluto solo (0,668), luego la normalización local es complementaria y no sustitutiva.

En SHAP domina `n_fuegos_10km_mismomes_hist` (0,612), y entre las meteorológicas puras `fwi_anom_sigma` (**0,516**) **supera al FWI absoluto (0,278)**: el modelo prioriza la normalización local. **Cuatro variables autorregresivas se eliminan de producción** porque con pseudo-ausencias de celda fija el incendio del positivo entra en el historial de los negativos posteriores de esa celda, y el modelo podría aprender orden temporal en vez de física. Coste medido y aceptado: AUC-PR 0,843 $\rightarrow$ 0,828.

4 Entrenamiento

Clasificación binaria supervisada sobre la unidad muestral (**celda de 1 km $\times$ día**): probabilidad de que ese día se *inicie* un incendio en esa celda. Se predice la ignición, no la propagación ni la severidad. Positivos: EGIF 2015–2020. **Pseudo-ausencias 1:3** —no existe un registro de “días sin incendio”, hay que construirlos— dentro del rango 1:1–1:10 de la literatura (Barbet-Massin *et al.*, 2012), tomando **la misma celda** en otras fechas. Split temporal congelado antes de extraer ninguna variable: train 2015–2018 / val 2019 / test 2020.

Algoritmo: XGBoost, elegido por datos tabulares, variables heterogéneas, interacciones no lineales y robustez a la falta de escalado. **Preprocesado que no se hace, y por que:** sin escalado, winsorización, imputación ni SMOTE, y **sin `scale_pos_weight`** —la salida se quiere como probabilidad, así que se conserva la prevalencia de diseño y se corrige con calibración isotónica ajustada en validación (van den Goorbergh *et al.*, 2022).

Hiperparametro	Base	Procedencia	Espacio Optuna	Optimo
<code>learning_rate</code>	0,05	Valor conservador	[0,01–0,15] log	0,0170
<code>max_depth</code>	6	Por defecto	[4–10]	10
<code>min_child_weight</code>	5	Sobre el defecto (1)	[1–30]	3
<code>subsample</code>	0,9	Rango habitual	[0,6–1,0]	0,892
<code>colsample_bytree</code>	0,8	Rango habitual	[0,5–1,0]	0,503
<code>reg_lambda</code>	1,0	Por defecto	[0,1–20] log	0,716
<code>gamma</code>	—	—	[0–5]	0,0106
<code>n_estimators</code>	3000	Tope; lo decide el <i>early stopping</i> (paciencia 100)		

Tabla 3: Hiperparámetros: procedencia de cada valor y búsqueda bayesiana.

El numero de arboles no se elige a mano: sale del *early stopping* sobre el AUC-PR de validacion (v1 489, v2 de produccion 240, v3 590, v4 732). [PDTE] el .ubj de v4 contiene 832 arboles frente a los 732 de su metadata: verificar cual se sirve.

La busqueda propia y su resultado, que es la parte interesante. Optuna con muestreador TPE, 40 *trials*, objetivo AUC-PR sobre la validacion de 2019 y el test de 2020 intacto. El mejor *trial* da **0,8666** frente a **0,8647** de la configuracion base: una ganancia de **+0,0019**. El presupuesto fue corto a proposito, bajo la hipotesis previa de que *el retorno esta en las variables y no en el ajuste*; el experimento la confirma. **En este problema el tuning es irrelevante frente al diseno del conjunto de entrenamiento**, que es justamente la tesis de los dos capitulos siguientes.

Se arrastran las dos configuraciones y se elige en validacion. La ajustada gana +0,0014 de AUC-PR ... y **multiplica por ~13 el tamano del modelo (11 MB frente a 840 KB)** al pasar `max_depth` de 6 a 10. Como el fichero viaja en el repositorio que ejecuta la cadena diaria en GitHub Actions, se produce tambien una variante ligera con los parametros base: una milésima de AUC-PR no compensa trece veces el peso. La seleccion de hiperparametros, del numero de arboles y del umbral de alerta se hace **siempre en validacion**; el test se toca una vez. Se anade una **validacion cruzada espacial** (`GroupKFold` por bloque de 100 km) para medir generalizacion a zonas no vistas.

5 Evaluacion del primer modelo, y el diagnostico

En test, las metricas son buenas: AUC-ROC **0,931** y AUC-PR 0,843 (v1/v2, test 2020); 0,891 [0,864, 0,914] en la version v4 sobre test 2022. Un control con las etiquetas barajadas al azar da AUC-PR 0,231 $\approx$ prevalencia base, lo que descarta fuga de informacion. **Advertencia obligatoria:** ese AUC-PR *no es comparable con la literatura*, porque corresponde a una prevalencia de diseno del 26,28 % frente a una prevalencia real del orden de 10^{-5} (§2). Solo el AUC-ROC admite comparacion aproximada.

En operacion, el mismo modelo rinde **0,56–0,64**. La distancia entre 0,89 y 0,64 es el verdadero objeto de este trabajo. Se persiguieron **tres explicaciones, en este orden, y las dos primeras se descartaron con numeros** —esa es la razon de que la tercera sea creible.

(a) **¿Esta mal medido?** No. Cinco *scores* compitieron contra tres verdades-terreno independientes (focos FIRMS, perimetros EFFIS y partes del MITECO) sobre 20 dias sellados, y ninguna diferencia resulto significativa. De paso corrigio un error propio: la linea base dura no es el FWI crudo sino **el percentil local**, y al acumular dias subio de 0,540 a **0,702** mientras el modelo apenas se movia. La conclusion anterior —“el modelo bate al FWI”, con dos o tres dias de muestra— era un artefacto del tamano muestral.

(b) **¿Es la meteorologia?** No, o no basta. Es la hipotesis mas plausible y hubo que agotarla: 24 *scripts* midiendo el desplazamiento de fuente entre ERA5-Land y AEMET variable a variable. Salieron dos cosas firmes —la precipitacion no coincide (+8,00 mm/30 dias) y la climatologia del percentil cruzaba fuentes, saturando la variable (12,6 % de las filas en percentil $\geq 99,9$ en produccion frente al 1,0 % en entrenamiento)— pero ninguna explica el hueco.

(c) **¿Es el desajuste train/serve?** Tampoco. La ablacion de los *proxis* que usa produccion —satelite sustituido por climatologia mensual, rayos servidos a cero— cuesta **−0,0045** de AUC en test. De regalo: las cinco variables satelitales no aportan nada ni siendo reales.

(d) **Es la especificacion.** Dos medidas, y con ellas el trabajo cambia de direccion:

- El **98,8 %** de las celdas del conjunto tenia exactamente un 25 % de positivos. El modelo no podia aprender que celda es mas peligrosa que otra: **solo que día lo es**.
- El **AUC caso-control de los dos disenos es identico (0,92)**, y el **AUC dentro del día los separa (0,744 frente a 0,828)**. La metrica de desarrollo era ciega a la diferencia que importaba.

No es un problema de ajuste. La pregunta que se entreno —“¿es hoy peligroso en esta celda?”— **no es la que se evalua en operacion** —“¿cual de las 498.530 celdas arde hoy?”. Y la evidencia estaba a la vista desde el capitulo 2: la prevalencia cinco ordenes de magnitud por encima de la real, y las variables de la celda con mediana identica en positivos y negativos.

6 Segunda iteracion: reentrenar cambiando la pregunta

Dos cambios, y nada mas. Los negativos pasan de ser *la misma celda en otros dias* a **otras celdas el mismo día**, y la etiqueta pasa de la ignicion EGIF a la **superficie quemada EFFIS** (`is_fire` del cubo). **Las 46 variables son las mismas a proposito:** si algo mejora, no puede atribuirse a informacion nueva. Los hiperparametros tambien se heredan literalmente, por la misma razon —asi la diferencia medida es del diseno muestral y no de un ajuste distinto.

Positivos: primer día EFFIS, con tope de 30 por día $\times$ bloque de 100 km para que un episodio grande no

domine. Split: train 2015–2022 / val 2023 / test 2024, con 2026 como conjunto externo; *early stopping* en 2023, que para en **441 árboles**.

La ablacion del ratio de pseudo-ausencias. El 1:3 venia heredado de la literatura y nunca se habia justificado con datos propios. Se barre la escalera 1:3 → 1:10 → 1:30 → 1:60 → 1:100 sobre **los mismos positivos y con los 441 árboles congelados** —con mas negativos cambia la prevalencia de la validacion y el *early stopping* pararia en otro punto, de modo que la comparacion mediria el ratio *y* el numero de árboles a la vez.

El optimo es interior, en **1:10–1:30**; desde 1:60 empeora (1:100 pierde $-0,013$ en 2026). Pero la ganancia en AUC medio ($+0,006$ a $+0,017$) **es del orden del ruido del sorteo de negativos** (0,005, medido re-sortando la misma receta), asi que no se vende como mejora. Lo que si mejora de forma consistente es el fuego grande: el **percentil ponderado por hectareas sube de 81,7 a 87,6–87,9**. Es el resultado que justifica servir el 1:10.

Otras dos ablaciones, ambas negativas y las dos utiles: **entrenar solo con verano empeora el DONDE**, coherente con el 38 % de igniciones de febrero a abril del capitulo 2; y **anadir una capa de “ya quemado” cuesta $-0,02$** , porque la etiqueta EFFIS penaliza bajar el riesgo sobre la cicatriz reciente.

De aqui salen tres modelos: el **unico** (*donde_dia_effis*, las 46 variables con muestreo del mismo dia), el **donde** (una fila por celda, sin meteorologia: su mapa es el mismo todos los dias) y el **cuando** (solo las 29 dinamicas servibles); la **pareja** es el producto de los dos ultimos.

► **Figura 6.1** — AUC y percentil ponderado por hectareas frente al ratio, con la banda de ruido del sorteo superpuesta.

7 Evaluacion del segundo ciclo

En validacion y test. AUC *dentro del dia* sobre el banco de evaluacion (celdas EFFIS de primer dia contra 1.000 celdas al azar del mismo dia), con IC95 por *bootstrap* de dias:

Modelo	Val 2023 (37 d, 223 pos.)	Test 2024 (72 d, 943 pos.)
Produccion (xgb_v2_prototipo)	0,723	0,792
Unico donde_dia_effis	0,836 ($\Delta +0,113$ [$+0,051$, $+0,176$])	0,809 ($\Delta +0,017$ [$-0,024$, $+0,063$])
cuando_effis	0,628	0,687
fwi_pctl_local (base sin ML)	0,680	0,636

Tabla 4: AUC dentro del dia en validacion y test.

Hay que leerlo con honestidad, y da un argumento mejor que esconderlo: en 2023 el unico gana con claridad y su intervalo no toca el cero, pero **en test 2024 la ventaja se encoge a $+0,017$ y el intervalo lo cruza**. 2024 fue un ano tranquilo —1,82 celdas-dia por 100.000 frente a las 14,16 de 2022— y 72 dias con 943 positivos no bastan para separar dos modelos que se llevan dos centesimas. La conclusion metodologica es que **el test de 2024 no tiene potencia suficiente**: un modelo de riesgo se juzga en la temporada, no en un conjunto reservado.

En la temporada 2026, externa y sellada, el unico da **AUC medio 0,751 frente a 0,644** de produccion — $\Delta +0,106$ IC [$+0,067$, $+0,148$], ganando el 70 % de los dias—, y la variante **1:10 llega a 0,758** ($\Delta +0,114$ [$+0,074$, $+0,154$], 73 % de los dias) con el mejor percentil ponderado por hectareas. La pareja se queda en 0,702.

Prevision contra prevision, el unico experimento sin retrovisor para nadie (19 dias): ranking sellado 0,568, **unico 0,605** ($\Delta +0,036$, gana 14/19 dias), malla 0,547. Por celda, 0,755 frente a 0,669. Es la primera vez que el modelo nuevo bate a produccion **por estacion**, la geometria donde siempre perdia.

Validacion prospectiva. Sellado el modelo, se puntua dia a dia hacia delante contra tres jueces que no intervinieron en el entrenamiento: EFFIS (perimetros, 45 dias de latencia), MITECO (parte diario D+1) y el ranking por estacion meteorologica del sistema en produccion. **[PDTE] actualizar a la fecha de cierre.**

Limitaciones. La probabilidad *ordena, pero no es una probabilidad real*: esta referida a la prevalencia de diseno. Ninguna etiqueta de validacion coincide con la de entrenamiento. Los intervalos de la validacion prospectiva son anchos. Persiste un desajuste train/serve conocido: cuatro variables de vegetacion del dia se sustituyen al servir por climatologia mensual, y pesan el 5,5 % del *gain*. Y se documentan dias de fallo con incendios sin senal meteorologica previa: el limite de un modelo alimentado por meteorologia cuando la causa es humana e inmediata en el 97 % de los casos.

► **Figuras 7.1–7.2** — distribucion diaria de Δ AUC con su intervalo; mapa nacional de riesgo de un dia con incendio, con los focos reales superpuestos *a posteriori*.

8 Repositorio y conclusion

El trabajo se acompaña de un repositorio con el árbol espejo de estos capítulos, trazabilidad de cada cifra al *script* que la produce, y muestras que permiten ejecutar la rama de servicio sin el cubo. Contiene además **mas figuras y mas analisis de los que caben aqui**: el exploratorio completo, las ablaciones enteras y los mapas diarios.

La lección del trabajo no es que modelo gana, sino que **una *target* mal alineada con la pregunta de produccion produce metricas excelentes y un sistema inutil**. El primer ciclo era metodologicamente correcto —particion temporal congelada, control anti-fuga, calibracion, validacion cruzada espacial— y aun asi no servia. Lo que lo arreglo no fue un algoritmo mejor ni mas hiperparametros —el ajuste bayesiano aportó +0,0019—, sino **volver a formular la unidad muestral** para que la pregunta entrenada fuese la pregunta evaluada.