

Predicción diaria del riesgo de incendio: dónde y cuándo

1 Objetivo y resultado

La España peninsular y Baleares se representan en 498,530 celdas de un kilómetro de lado. El objetivo de este módulo es ordenar cada mañana esas celdas de mayor a menor riesgo de incendio para el día en curso. Su calidad se mide con un solo criterio: si las celdas que ardieron ese día ocupaban las primeras posiciones. Dentro del sistema conjunto, este módulo cubre el 'antes' del incendio. La visión por computador cubre el 'durante' y el asistente sobre los partes del MITECO (Ministerio para la Transición Ecológica y el Reto Demográfico), la consulta.

El trabajo se desarrolló en dos iteraciones. Un primer modelo alcanzó un AUC (*Area Under the ROC Curve*) de 0.89 en su conjunto de prueba. Puesto en producción y evaluado contra la superficie quemada real, obtuvo entre 0.57 y 0.64. El problema no era el algoritmo ni el clima. El modelo respondía a una pregunta que no interesaba, dejando la verdadera cuestión sin resolver. Con el diseño corregido, el segundo modelo pasó de 0.74 a 0.81 en la temporada de 2025 y de 0.66 a 0.76 en la de 2026, evaluado día a día sobre las dos temporadas completas.

2 Datos

Se emplearon cuatro fuentes, descritas en el anexo A:

- IberFire, un cubo de datos abierto (Tekniker y UPV/EHU, Universidad del País Vasco / Euskal Herriko Unibertsitatea). Contiene 261 variables diarias por celda de 1 km entre 2008 y 2024: meteorología, vegetación, relieve, usos del suelo, población y carreteras. De él proceden casi todas las variables del modelo.
- EGIF (Estadística General de Incendios Forestales), el registro oficial de incendios del Ministerio. Tiene una fila por incendio, con su fecha y el punto de inicio. Es la etiqueta del primer modelo.
- EFFIS (*European Forest Fire Information System*), los perímetros de superficie quemada que Copernicus cartografía por satélite. Es la etiqueta del segundo modelo y la verdad contra la que se evalúan los dos.
- ERA5-Land (*ECMWF Reanalysis v5 Land*) e IFS (*Integrated Forecasting System*), ambos del ECMWF (*European Centre for Medium-Range Weather Forecasts*). El primero es el reanálisis meteorológico, que describe lo ocurrido; el segundo es la previsión. Se entrena con el reanálisis y se sirve con la previsión. El primer modelo se sirvió con la observación de 687 estaciones de AEMET (Agencia Estatal de Meteorología).

A partir de estas fuentes se construyen 46 variables por celda y día, en cuatro familias. La meteorología: temperatura, humedad, viento, precipitación del día y de los últimos 7, 15 y 30 días, y el índice de peligro FWI (*Fire Weather Index*). Las características de la celda: bosque, matorral, pendiente, altitud, carreteras y población. El historial de fuego del entorno: incendios a 1 y 10 km en meses y años anteriores, y focos térmicos de satélite en la última semana. Y el calendario.

El análisis exploratorio aportó tres resultados principales. El primero es la escasez del fenómeno. En la mayoría de los veranos de 2015 a 2024 hubo entre 2 y 7 celdas ardiendo por cada 100,000 al día, según los perímetros de EFFIS. Además, solo el 3 % de las celdas registró alguna ignición entre 2015 y 2020, según la EGIF.

El segundo es la agrupación espacial. Las celdas quemadas son contiguas, porque proceden de perímetros. Por eso una partición aleatoria entre entrenamiento y prueba aumenta el AUC, por esto se hicieron las particiones del trabajo por bloques de 100 km o por años.

El tercero afecta al FWI. Su valor absoluto toma valores de significado distinto según el lugar: un FWI de 40 es habitual en Almería y excepcional en Asturias. Lo que separa los días con fuego es lo inusual que resulta ese valor en cada celda. Por ello el FWI se expresa como percentil respecto a la historia de la propia celda. En el conjunto de entrenamiento, la mediana de ese percentil es 84 en los días con fuego y 47 en los días sin fuego.

3 Primer modelo: entrenamiento y evaluación en operación

El primer modelo se construyó con el diseño habitual en la literatura. Los positivos fueron los 19,561 incendios del registro EGIF entre 2015 y 2020, cada uno en su celda y su fecha. Los negativos se tomaron de la misma celda en otros días sin incendio, tres por cada positivo. Se entrenó un modelo XGBoost (*eXtreme Gradient Boosting*) y se ajustó con los datos de 2021. Se probó con los de 2022, el peor año de la década, que incluye los incendios de Losacio y la Sierra de la Culebra. El resultado fue un AUC de 0.89. No había fugas de información (con las etiquetas barajadas el modelo cae al azar) ni pérdida apreciable al validarlo por bloques espaciales de 100 km. El ajuste de hiperparámetros añadió solo +0.007, por lo que el rendimiento procedía de las variables.

Con ese resultado, el modelo se puso en producción en julio de 2026. Cada mañana descarga la observación de las 687 estaciones, calcula las 46 variables y publica un ranking nacional y un mapa de riesgo para el día y el siguiente. Desde entonces se ejecuta a diario.

La evaluación se hizo contra tres fuentes de datos independientes: los perímetros de EFFIS, los partes diarios del MITECO y los focos térmicos de satélite. El acierto diario del modelo en producción se situó entre 0.57 y 0.64. Un índice sin modelo, el percentil local del FWI, alcanzó 0.70. Se consideraron tres explicaciones, y las dos primeras se descartaron:

1. La medida no era el problema. Las tres verdades, procedentes de satélite, de cartografía y de partes oficiales, coincidían.

2. La meteorología tampoco. El modelo se entrenó con el reanálisis del cubo y se sirve con estaciones, y hay diferencias reales entre las dos fuentes: el reanálisis registra 8 mm más de lluvia al mes, lo que reduce el FWI en 10 puntos. Cuantificadas, esas diferencias no explican la caída. Tampoco la explica lo que cambia entre entrenamiento y servicio: sustituir las variables de satélite por su climatología cuesta 0.0045 de AUC.
3. La causa estaba en la pregunta. Al tomar los negativos de la misma celda en otros días, el 98.8 % de las celdas de la muestra tenía exactamente un 25 % de días con fuego. Con la misma proporción en todas las celdas, el modelo no podía aprender qué celda es más peligrosa que otra; solo podía aprender qué día lo es. El modelo respondía a «¿es hoy un día peligroso en esta celda?». En operación se le preguntaba «¿cuál de las 498,530 celdas arde hoy?».

4 Segundo modelo: mismo algoritmo, distinta pregunta

Se comienza analizando la figura 1 que resume el problema y su solución. En el primer diseño (a), cada celda quemada se compara consigo misma en otros días. En el segundo (b), se compara con otras celdas del mismo día, que es lo que se pide en operación (c). La prueba de que ese era el fallo es que la métrica de laboratorio no lo detectaba. Dos conjuntos de entrenamiento, uno con cada diseño, obtuvieron 0.92 medidos cada uno con su propio conjunto de prueba. Medidos dentro de cada día, como se usan, obtuvieron 0.744 y 0.828.



Figura 1: La misma rejilla celda $\times$ día con los dos diseños de muestreo y la pregunta operativa. (a) Primera iteración: para cada celda quemada, los negativos son la misma celda en otros días, y el modelo solo puede aprender qué día es peligroso. (b) Segunda iteración: los negativos son otras celdas del mismo día, y el modelo aprende a comparar celdas. (c) Lo que se pide cada mañana: ordenar todas las celdas del día. Solo (b) plantea la misma pregunta que (c).

La segunda versión cambió dos elementos y mantuvo el resto: las mismas 46 variables, el mismo algoritmo con los mismos hiperparámetros y la misma malla. Los negativos pasaron a ser otras celdas del mismo día. La etiqueta pasó a ser la superficie quemada de EFFIS, la misma con la que se evalúa. Este segundo cambio responde a una comprobación previa: solo el 15 % de las igniciones de EGIF de entre 25 y 100 hectáreas coincidía, en la misma celda y fecha, con un perímetro de EFFIS. Entrenar con puntos de ignición y evaluar con perímetros equivalía a comparar dos magnitudes distintas.

Con el nuevo diseño se entrenó con los años 2015 a 2022, se ajustó con 2023 y se probó con 2024, siempre evaluando dentro de cada día. Se compararon dos alternativas: un modelo único, y la combinación de un modelo de «dónde» (estático) con otro de «cuándo» (diario). También se probaron distintas cantidades de negativos por positivo. Se eligió el modelo único con diez negativos por positivo, denominado r10 en adelante.

La elección se apoyó en la temporada de 2026, externa al cubo y con 74 días con fuego. Frente a la pareja, el modelo único ordenó mejor las celdas de cada día: 0.752 frente a 0.705 de AUC medio. En la prueba de 2024 la pareja había quedado por delante (0.840 frente a 0.809), pero perdió esa ventaja en 2026. Frente a otras cantidades de negativos, el acierto medio apenas cambió, entre 0.745 y 0.759, del orden del ruido del sorteo. Diez negativos por positivo situaron mejor los incendios grandes: el percentil medio de las celdas quemadas, ponderado por hectáreas, pasó de 79.5 con tres negativos a 81.9 con diez. La reproducción posterior de las temporadas de 2025 y 2026 confirmó la elección. De los seis modelos comparados, el r10 obtuvo el mayor AUC medio en las dos, con un protocolo de evaluación fijado por escrito antes de ejecutarla.

Las pruebas con resultado negativo se recogen en el anexo B: entrenar solo con verano y añadir una capa de 'ya quemado' empeoran el modelo.

Antes de dar por bueno el modelo se comprobó en qué variables se apoya y si eso concuerda con lo que se sabe del fuego (figura 2). La variable de mayor peso es el historial: el número de incendios a 10 km en el mismo mes de años anteriores. Le siguen el combustible (verdor acumulado en el último mes, matorral y pendiente) y la meteorología.

Una humedad mínima baja y un FWI anómalo para la celda elevan el riesgo; el suelo agrícola y la lluvia reciente lo reducen. El verdor y la temperatura de superficie del propio día contienen ya parte de la firma del incendio en el cubo, y suponen un 4 % del peso del modelo. En servicio se sustituyen por su climatología mensual, porque no fue posible disponer de ellos en producción.




Figura 2: Variables en las que se apoya el r10: las 15 de mayor peso según los valores SHAP (*SHapley Additive exPlanations*) sobre 6,000 celdas-día de los veranos de 2023 y 2024, que el modelo no vio al entrenar. A la izquierda, la importancia media. A la derecha, el efecto de cada fila (a la derecha del cero eleva el riesgo), con el valor de la variable en color (rojo, alto). Historial de fuego, combustible y sequedad, por ese orden.

5 Resultados, límites y conclusiones

Para comparar los dos modelos en igualdad de condiciones se reprodujeron día a día las temporadas de 2025 (del 1 de junio al 1 de noviembre) y de 2026 (hasta el 2 de septiembre). Ambos modelos recibieron la previsión disponible la víspera y se evaluaron con los perímetros de EFFIS. La tabla 1 recoge los resultados.

Tabla 1. Acierto medio por día (AUC dentro del día) del modelo de producción y del r10 con la previsión de la víspera, evaluados con EFFIS. La diferencia es la media pareada día a día, con IC (intervalo de confianza) bootstrap al 95 %.

Temporada	Días con fuego	Hectáreas	Producción	r10	Diferencia (IC 95 %)	Días que gana el r10
2025	138	387,000	0.743	0.807	+0.064 [+0.027, +0.101]	60 %
2026	86	268,000	0.658	0.762	+0.104 [+0.065, +0.144]	67 %

De la tabla se extraen tres lecturas. La primera: el intervalo no incluye el cero en ninguna temporada, y el r10 gana dos de cada tres días, con más ventaja en 2026, la temporada en la que el modelo de producción obtuvo peores resultados.

La segunda: usar la previsión meteorológica de la víspera no supone un coste. Cada día se calculó también con el tiempo realmente observado, y la diferencia de AUC es de -0.003 , con un intervalo que incluye el cero. El modelo no depende de acertar el tiempo al detalle, sino de conocer dónde está el combustible y cuánto tiempo lleva seco.

La tercera: el mapa indica dónde vigilar, no dónde va a arder. Que una celda concreta arda un día concreto ocurre una vez de cada diez mil. El producto es una herramienta de vigilancia, no una alarma por celda.

Queda por resolver cómo presentar el resultado. Durante la temporada el mapa se pintó por posición en el ranking del día, con el 2 % superior en rojo. Esa regla señala dónde mirar, pero no cuánto riesgo hay: el ranking siempre tiene un primero, de modo que un día de febrero muestra tanto rojo como el 15 de agosto. Por ello se publican dos mapas del mismo modelo y una cifra (figura 3).

El primer mapa mantiene el percentil del día e indica las celdas prioritarias. El segundo fija los colores en la escala de la puntuación del modelo. Los cortes se obtuvieron de los 250 días de 2025 y 2026 calculados con la cadena de servicio, de forma que el nivel extremo reúne el 2 % de las celdas-día más altas de ese periodo. En ese nivel ardió una de cada 760 celdas-día, 13 veces la media de las dos temporadas (anexo C).

En la escala absoluta la cantidad de rojo cambia de un día a otro: el 13 de agosto de 2025 cubrió el 4.8 % de España y el 29 de octubre, el 0.3 %. Como la diferencia no siempre se aprecia a simple vista, el mapa se acompaña de una cifra: el porcentaje de España en nivel extremo y su posición entre los días de referencia. La cifra resume cuánto riesgo marca el mapa, pero anticipa con cautela los días con incendio grande: en 2025 y 2026 obtuvo un AUC de 0.69 y 0.66, frente a 0.74 y 0.44 del calendario.

La puntuación no es una probabilidad, sino un valor para ordenar y comparar con la historia.




Figura 3: El mismo modelo (r10) en un día de pleno verano (13 de agosto de 2025, arriba) y en uno fuera de temporada (29 de octubre de 2025, abajo). Izquierda: niveles por percentil del día, que asignan el 2 % de extremo todos los días. Derecha: cortes fijos en la escala de la puntuación y la cifra del día, es decir, el porcentaje de España en extremo y su posición entre los días de referencia. Los días de referencia son los 250 días de las temporadas de 2025 (del 25 de mayo al 1 de noviembre) y de 2026 (del 25 de mayo al 2 de septiembre), calculados igual que el mapa diario; de ellos salen también los cortes.

La propuesta tiene tres límites. La evaluación de las dos temporadas es a posteriori: los mapas usan la previsión de cada víspera, pero se generaron después y no se publicaron día a día. La escala absoluta se calibró con 250 días de temporada, sin datos de diciembre a abril, y su referencia debe ampliarse con cada día publicado. Y la cobertura se limita a la Península y Baleares, sin Canarias, con datos de 2026 hasta el 2 de septiembre.

Como conclusión, un modelo se optimiza para la pregunta que define su conjunto de entrenamiento. Esa pregunta la determinan la elección de positivos y negativos, no la intención de quien lo entrena. Un acierto alto sobre un conjunto de prueba construido con el mismo diseño que el de entrenamiento no garantiza nada sobre el uso previsto. Por ello, en la segunda iteración se evaluó cada día con la misma verdad con la que se entrena.

La utilidad del resultado se aprecia en la temporada completa de 2025 con el r10. Con un radio operativo de 6 km, se cubrió el 44 % de los incendios vigilando cerca del 10 % del territorio. Es un resultado notable en un fenómeno en el que, en verano, arden entre 2 y 7 celdas de cada 100,000 al día. Esa cobertura permite concentrar la vigilancia en las zonas señaladas, por ejemplo con visión artificial desde cámaras o drones. Permite también avisar a la población y desplegar recursos de forma preventiva, y reducir así el impacto económico, social y humano de los incendios forestales.

El código, con cada cifra enlazada al script que la produjo, está disponible en el repositorio (anexo D).

Anexos

Estos anexos recogen solo las tablas y figuras imprescindibles. El detalle de cada parte, con los scripts que produjeron cada cifra, está en el repositorio del trabajo (anexo D).

A Datos

Además de las cuatro fuentes del apartado de datos, se usaron la observación de 687 estaciones de AEMET (meteorología del primer modelo en producción), los focos térmicos de FIRMS (variables de fuego reciente) y los partes del MITECO (segunda referencia durante el desarrollo).

La figura 4 resume las dos propiedades de los datos que más condicionaron el diseño. La primera es la escasez: en verano arden entre 0.5 y 38 celdas de cada 100,000 al día, según el año, frente al 25 % de positivos del conjunto de la primera iteración. La segunda es la persistencia de la etiqueta de EFFIS: una celda que arde un día sigue marcada al siguiente con probabilidad 0.51, así que las evaluaciones cuentan solo el primer día de cada celda quemada.




Figura 4: (a) Celdas-día con fuego por cada 100,000, año completo y verano, en escala logarítmica, frente a la proporción de positivos del primer diseño. (b) Probabilidad de que una celda siga marcada como quemada k días después.

Las 46 variables y su orden están en `01_datos/comun/features.py`; la descarga y el tratamiento de cada fuente, en `01_datos/README.md`.

B Benchmark y alternativas descartadas

La figura 5 compara los seis modelos de la reproducción de 2025 y 2026, con la previsión de la víspera. Los dos modelos únicos encabezan las dos temporadas; la pareja supera a producción, pero queda por debajo; el modelo de «dónde» por separado no se distingue de producción y el de «cuándo» queda por debajo. La tabla 2 resume las alternativas al r10 que no se adoptaron.




Figura 5: Diferencia de AUC medio por día de cada modelo con producción, con su IC al 95 %. A la derecha de cada barra, el AUC medio del modelo. En rojo, el r10; en gris, los intervalos que incluyen el cero.

En superficie, el r10 situó en el 10 % de celdas de mayor riesgo de cada día el 63.0 % de las hectáreas quemadas en 2025 y el 37.0 % en 2026, frente al 59.6 y 24.7 % de producción. La pareja captó más superficie en 2025 (72.4 %) y menos en 2026 (23.7 %).

Tabla 2. Alternativas descartadas. Diferencia de AUC medio por día con la configuración de referencia de cada prueba.

Alternativa	Resultado
De 1:3 a 1:100 negativos por positivo	AUC de 2026 entre 0.745 y 0.759; el percentil ponderado por hectáreas fue máximo con 1:10 (81.9)
Entrenar solo con verano	Entre -0.011 y -0.041 en cuatro conjuntos de prueba
Apagar las celdas quemadas en los 7 a 60 días previos	Entre -0.017 y -0.027 en la temporada de 2026
Reentrenar el r10 con 2015–2024	$+0.0033$ [-0.0042 , $+0.0104$]: sin mejora

La reproducción completa, con la captura de hectáreas y el lift, está en `06_comparacion/README.md` y `docs/REPLAY_CAPTURA.md`; las alternativas, en `05_iteracion2/README.md`.

C Escala absoluta y cifra del día

Los cortes de la escala absoluta se obtuvieron de los 250 días de referencia, calculados igual que el mapa diario. Los cortes calculados con los diez años del cubo marcaban en esos mapas entre dos y diez veces más celdas en extremo que el cubo en el mismo mes. La tabla 3 da el significado de cada nivel.

Tabla 3. Niveles del r10 en los 250 días de referencia. Factor: frecuencia de quema del nivel dividida entre la media.

Nivel	Corte	Celdas-día (%)	Una quemada de cada	Factor	Hectáreas (%)
BAJO	0	30.0	132,600	0.08	1.5
MODERADO	0.0060	60.0	14,200	0.71	40.0
ALTO	0.1125	8.0	2,760	3.63	29.5
EXTREMO	0.4058	2.0	760	13.17	29.0

La cifra del día sitúa el porcentaje de España en extremo entre esos 250 días, cuya mediana es el 1.5 % y cuyo percentil 90 es el 4.6 %. Para separar los días con incendio grande obtuvo un AUC de 0.69 en 2025 y de 0.66 en 2026, frente a 0.74 y 0.44 del calendario. Los cortes deben recalcularse al acumular días publicados, en especial de diciembre a abril. El detalle, junto con el semáforo nacional que se evaluó y se descartó, está en `07_produccion/escala_y_cifra/README.md`.

D Limitaciones y repositorio

Tabla 4. Limitaciones principales.

Limitación	Efecto
Evaluación a posteriori	Los mapas de 2025 y 2026 usan la previsión de cada víspera, pero se generaron después; el protocolo se escribió antes de ejecutarlos
Escala absoluta	Calibrada con 250 días de temporada, sin diciembre a abril; con cortes de 2025, en 2026 el extremo pasó de una celda quemada de cada 550 a una de cada 2,560
Variables de vecindad	En el mapa diario son entre un 36 y un 54 % mayores que al entrenar; cambian la escala, no el orden de las celdas
Incertidumbre	El sorteo de negativos mueve el AUC 0.004; los IC suponen días independientes y son una cota inferior
Probabilidad por celda	Depende de la intensidad de la temporada (en julio, del 0.00 % en 2023 al 12.76 % en 2022); se publican niveles
Cobertura	Península y Baleares, sin Canarias, Ceuta ni Melilla; datos de 2026 hasta el 2 de septiembre

El repositorio (github.com/JuanUtrilla/tfm-riesgo-incendios) sigue el orden de esta memoria. Cada carpeta tiene un `README.md` con lo que hace cada script y para qué se usó (tabla 5).

Tabla 5. Dónde ampliar cada parte de la memoria.

Parte	Enlace
Datos y análisis exploratorio	<code>01_datos</code> · <code>02_edo</code>
Primer modelo y diagnóstico	<code>03_iteracion1</code> · <code>04_bisagra</code>
Segundo modelo y calibración	<code>05_iteracion2</code> · <code>05_iteracion2/56_calibracion</code>
Reproducción de 2025 y 2026	<code>06_comparacion</code> · <code>docs/REPLAY_VEREDICT0.md</code>
Mapa diario, escala y cifra	<code>07_produccion</code> · <code>07_produccion/escala_y_cifra</code>
Cifra a cifra: script y fichero de origen	<code>docs/TRAZABILIDAD.md</code>
Procedencia de cada fichero	<code>docs/PROCEDENCIA.md</code>