

Predicción diaria del riesgo de incendio: dónde y cuándo

1 Objetivo y resultado

La España peninsular y Baleares se representan en 498,530 celdas de un kilómetro de lado. El objetivo de este módulo es ordenar cada mañana esas celdas de mayor a menor riesgo de incendio para el día en curso. Su calidad se mide con un solo criterio: si las celdas que ardieron ese día ocupaban las primeras posiciones. Dentro del sistema conjunto, este módulo cubre el 'antes' del incendio. La visión por computador cubre el 'durante' y el asistente sobre los partes del MITECO (Ministerio para la Transición Ecológica y el Reto Demográfico), la consulta.

El trabajo se desarrolló en dos iteraciones. Un primer modelo alcanzó un AUC (*Area Under the ROC Curve*) de 0.89 en su conjunto de prueba. Puesto en producción y evaluado contra la superficie quemada real, obtuvo entre 0.57 y 0.64. El problema no era el algoritmo ni el clima. El modelo respondía a una pregunta que no interesaba, dejando la verdadera cuestión sin resolver. Con el diseño corregido, el segundo modelo pasó de 0.74 a 0.81 en la temporada de 2025 y de 0.66 a 0.76 en la de 2026, evaluado día a día sobre las dos temporadas completas.

2 Datos

Se emplearon cuatro fuentes, descritas en el anexo A:

- IberFire, un cubo de datos abierto (Tekniker y UPV/EHU, Universidad del País Vasco / Euskal Herriko Unibertsitatea). Contiene 261 variables diarias por celda de 1 km entre 2008 y 2024: meteorología, vegetación, relieve, usos del suelo, población y carreteras. De él proceden casi todas las variables del modelo.
- EGIF (Estadística General de Incendios Forestales), el registro oficial de incendios del Ministerio. Tiene una fila por incendio, con su fecha y el punto de inicio. Es la etiqueta del primer modelo.
- EFFIS (*European Forest Fire Information System*), los perímetros de superficie quemada que Copernicus cartografía por satélite. Es la etiqueta del segundo modelo y la verdad contra la que se evalúan los dos.
- ERA5-Land (*ECMWF Reanalysis v5 Land*) e IFS (*Integrated Forecasting System*), ambos del ECMWF (*European Centre for Medium-Range Weather Forecasts*). El primero es el reanálisis meteorológico, que describe lo ocurrido; el segundo es la previsión. Se entrena con el reanálisis y se sirve con la previsión. El primer modelo se sirvió con la observación de 687 estaciones de AEMET (Agencia Estatal de Meteorología).

A partir de estas fuentes se construyen 46 variables por celda y día, en cuatro familias. La meteorología: temperatura, humedad, viento, precipitación del día y de los últimos 7, 15 y 30 días, y el índice de peligro FWI (*Fire Weather Index*). Las características de la celda: bosque, matorral, pendiente, altitud, carreteras y población. El historial de fuego del entorno: incendios a 1 y 10 km en meses y años anteriores, y focos térmicos de satélite en la última semana. Y el calendario.

El análisis exploratorio aportó tres resultados principales. El primero es la escasez del fenómeno. En la mayoría de los veranos de 2015 a 2024 hubo entre 2 y 7 celdas ardiendo por cada 100,000 al día, según los perímetros de EFFIS. Además, solo el 3 % de las celdas registró alguna ignición entre 2015 y 2020, según la EGIF.

El segundo es la agrupación espacial. Las celdas quemadas son contiguas, porque proceden de perímetros. Por eso una partición aleatoria entre entrenamiento y prueba aumenta el AUC, por esto se hicieron las particiones del trabajo por bloques de 100 km o por años.

El tercero afecta al FWI. Su valor absoluto toma valores de significado distinto según el lugar: un FWI de 40 es habitual en Almería y excepcional en Asturias. Lo que separa los días con fuego es lo inusual que resulta ese valor en cada celda. Por ello el FWI se expresa como percentil respecto a la historia de la propia celda. En el conjunto de entrenamiento, la mediana de ese percentil es 84 en los días con fuego y 47 en los días sin fuego.

3 Primer modelo: entrenamiento y evaluación en operación

El primer modelo se construyó con el diseño habitual en la literatura. Los positivos fueron los 19,561 incendios del registro EGIF entre 2015 y 2020, cada uno en su celda y su fecha. Los negativos se tomaron de la misma celda en otros días sin incendio, tres por cada positivo. Se entrenó un modelo XGBoost (*eXtreme Gradient Boosting*) y se ajustó con los datos de 2021. Se probó con los de 2022, el peor año de la década, que incluye los incendios de Losacio y la Sierra de la Culebra. El resultado fue un AUC de 0.89. No había fugas de información (con las etiquetas barajadas el modelo cae al azar) ni pérdida apreciable al validarlo por bloques espaciales de 100 km. El ajuste de hiperparámetros añadió solo +0.007, por lo que el rendimiento procedía de las variables.

Con ese resultado, el modelo se puso en producción en julio de 2026. Cada mañana descarga la observación de las 687 estaciones, calcula las 46 variables y publica un ranking nacional y un mapa de riesgo para el día y el siguiente. Desde entonces se ejecuta a diario.

La evaluación se hizo contra tres fuentes de datos independientes: los perímetros de EFFIS, los partes diarios del MITECO y los focos térmicos de satélite. El acierto diario del modelo en producción se situó entre 0.57 y 0.64. Un índice sin modelo, el percentil local del FWI, alcanzó 0.70. Se consideraron tres explicaciones, y las dos primeras se descartaron:

1. La medida no era el problema. Las tres verdades, procedentes de satélite, de cartografía y de partes oficiales, coincidían.

2. La meteorología tampoco. El modelo se entrenó con el reanálisis del cubo y se sirve con estaciones, y hay diferencias reales entre las dos fuentes: el reanálisis registra 8 mm más de lluvia al mes, lo que reduce el FWI en 10 puntos. Cuantificadas, esas diferencias no explican la caída. Tampoco la explica lo que cambia entre entrenamiento y servicio: sustituir las variables de satélite por su climatología cuesta 0.0045 de AUC.
3. La causa estaba en la pregunta. Al tomar los negativos de la misma celda en otros días, el 98.8 % de las celdas de la muestra tenía exactamente un 25 % de días con fuego. Con la misma proporción en todas las celdas, el modelo no podía aprender qué celda es más peligrosa que otra; solo podía aprender qué día lo es. El modelo respondía a «¿es hoy un día peligroso en esta celda?». En operación se le preguntaba «¿cuál de las 498,530 celdas arde hoy?».

4 Segundo modelo: mismo algoritmo, distinta pregunta

Se comienza analizando la figura 1 que resume el problema y su solución. En el primer diseño (a), cada celda quemada se compara consigo misma en otros días. En el segundo (b), se compara con otras celdas del mismo día, que es lo que se pide en operación (c). La prueba de que ese era el fallo es que la métrica de laboratorio no lo detectaba. Dos conjuntos de entrenamiento, uno con cada diseño, obtuvieron 0.92 medidos cada uno con su propio conjunto de prueba. Medidos dentro de cada día, como se usan, obtuvieron 0.744 y 0.828.



Figura 1: La misma rejilla celda $\times$ día con los dos diseños de muestreo y la pregunta operativa. (a) Primera iteración: para cada celda quemada, los negativos son la misma celda en otros días, y el modelo solo puede aprender qué día es peligroso. (b) Segunda iteración: los negativos son otras celdas del mismo día, y el modelo aprende a comparar celdas. (c) Lo que se pide cada mañana: ordenar todas las celdas del día. Solo (b) plantea la misma pregunta que (c).

La segunda versión cambió dos elementos y mantuvo el resto: las mismas 46 variables, el mismo algoritmo con los mismos hiperparámetros y la misma malla. Los negativos pasaron a ser otras celdas del mismo día. La etiqueta pasó a ser la superficie quemada de EFFIS, la misma con la que se evalúa. Este segundo cambio responde a una comprobación previa: solo el 15 % de las igniciones de EGIF de entre 25 y 100 hectáreas coincidía, en la misma celda y fecha, con un perímetro de EFFIS. Entrenar con puntos de ignición y evaluar con perímetros equivalía a comparar dos magnitudes distintas.

Con el nuevo diseño se entrenó con los años 2015 a 2022, se ajustó con 2023 y se probó con 2024, siempre evaluando dentro de cada día. Se compararon dos alternativas: un modelo único, y la combinación de un modelo de «dónde» (estático) con otro de «cuándo» (diario). También se probaron distintas cantidades de negativos por positivo. Se eligió el modelo único con diez negativos por positivo, denominado r10 en adelante.

La elección se apoyó en la temporada de 2026, externa al cubo y con 74 días con fuego. Frente a la pareja, el modelo único ordenó mejor las celdas de cada día: 0.752 frente a 0.705 de AUC medio. En la prueba de 2024 la pareja había quedado por delante (0.840 frente a 0.809), pero perdió esa ventaja en 2026. Frente a otras cantidades de negativos, el acierto medio apenas cambió, entre 0.745 y 0.759, del orden del ruido del sorteo. Diez negativos por positivo situaron mejor los incendios grandes: el percentil medio de las celdas quemadas, ponderado por hectáreas, pasó de 79.5 con tres negativos a 81.9 con diez. La reproducción posterior de las temporadas de 2025 y 2026 confirmó la elección. De los seis modelos comparados, el r10 obtuvo el mayor AUC medio en las dos, con un protocolo de evaluación fijado por escrito antes de ejecutarla.

Las pruebas con resultado negativo se recogen en el anexo B: entrenar solo con verano y añadir una capa de 'ya quemado' empeoran el modelo.

Antes de dar por bueno el modelo se comprobó en qué variables se apoya y si eso concuerda con lo que se sabe del fuego (figura 2). La variable de mayor peso es el historial: el número de incendios a 10 km en el mismo mes de años anteriores. Le siguen el combustible (verdor acumulado en el último mes, matorral y pendiente) y la meteorología.

Una humedad mínima baja y un FWI anómalo para la celda elevan el riesgo; el suelo agrícola y la lluvia reciente lo reducen. El verdor y la temperatura de superficie del propio día contienen ya parte de la firma del incendio en el cubo, y suponen un 4 % del peso del modelo. En servicio se sustituyen por su climatología mensual, porque no fue posible disponer de ellos en producción.




Figura 2: Variables en las que se apoya el r10: las 15 de mayor peso según los valores SHAP (*SHapley Additive exPlanations*) sobre 6,000 celdas-día de los veranos de 2023 y 2024, que el modelo no vio al entrenar. A la izquierda, la importancia media. A la derecha, el efecto de cada fila (a la derecha del cero eleva el riesgo), con el valor de la variable en color (rojo, alto). Historial de fuego, combustible y sequedad, por ese orden.

5 Resultados, límites y conclusiones

Para comparar los dos modelos en igualdad de condiciones se reprodujeron día a día las temporadas de 2025 (del 1 de junio al 1 de noviembre) y de 2026 (hasta el 2 de septiembre). Ambos modelos recibieron la previsión disponible la víspera y se evaluaron con los perímetros de EFFIS. La tabla 1 recoge los resultados.

Tabla 1. Acierto medio por día (AUC dentro del día) del modelo de producción y del r10 con la previsión de la víspera, evaluados con EFFIS. La diferencia es la media pareada día a día, con IC (intervalo de confianza) bootstrap al 95 %.

Temporada	Días con fuego	Hectáreas	Producción	r10	Diferencia (IC 95 %)	Días que gana el r10
2025	138	387,000	0.743	0.807	+0.064 [+0.027, +0.101]	60 %
2026	86	268,000	0.658	0.762	+0.104 [+0.065, +0.144]	67 %

De la tabla se extraen tres lecturas. La primera: el intervalo no incluye el cero en ninguna temporada, y el r10 gana dos de cada tres días, con más ventaja en 2026, la temporada en la que el modelo de producción obtuvo peores resultados.

La segunda: usar la previsión meteorológica de la víspera no supone un coste. Cada día se calculó también con el tiempo realmente observado, y la diferencia de AUC es de -0.003 , con un intervalo que incluye el cero. El modelo no depende de acertar el tiempo al detalle, sino de conocer dónde está el combustible y cuánto tiempo lleva seco.

La tercera: el mapa indica dónde vigilar, no dónde va a arder. Que una celda concreta arda un día concreto ocurre una vez de cada diez mil. El producto es una herramienta de vigilancia, no una alarma por celda.

Queda por resolver cómo presentar el resultado. Durante la temporada el mapa se pintó por posición en el ranking del día, con el 2 % superior en rojo. Esa regla señala dónde mirar, pero no cuánto riesgo hay: el ranking siempre tiene un primero, de modo que un día de febrero muestra tanto rojo como el 15 de agosto. Por ello se publican dos mapas del mismo modelo y una cifra (figura 3).

El primer mapa mantiene el percentil del día e indica las celdas prioritarias. El segundo fija los colores en la escala de la puntuación del modelo. Los cortes se obtuvieron de los 250 días de 2025 y 2026 calculados con la cadena de servicio, de forma que el nivel extremo reúne el 2 % de las celdas-día más altas de ese periodo. En ese nivel ardió una de cada 760 celdas-día, 13 veces la media de las dos temporadas (anexo C).

En la escala absoluta la cantidad de rojo cambia de un día a otro: el 13 de agosto de 2025 cubrió el 4.8 % de España y el 29 de octubre, el 0.3 %. Como la diferencia no siempre se aprecia a simple vista, el mapa se acompaña de una cifra: el porcentaje de España en nivel extremo y su posición entre los días de referencia. La cifra resume cuánto riesgo marca el mapa, pero anticipa con cautela los días con incendio grande: en 2025 y 2026 obtuvo un AUC de 0.69 y 0.66, frente a 0.74 y 0.44 del calendario.

La puntuación no es una probabilidad, sino un valor para ordenar y comparar con la historia.




Figura 3: El mismo modelo (r10) en un día de pleno verano (13 de agosto de 2025, arriba) y en uno fuera de temporada (29 de octubre de 2025, abajo). Izquierda: niveles por percentil del día, que asignan el 2 % de extremo todos los días. Derecha: cortes fijos en la escala de la puntuación y la cifra del día, es decir, el porcentaje de España en extremo y su posición entre los días de referencia. Los días de referencia son los 250 días de las temporadas de 2025 (del 25 de mayo al 1 de noviembre) y de 2026 (del 25 de mayo al 2 de septiembre), calculados igual que el mapa diario; de ellos salen también los cortes.

La propuesta tiene tres límites. La evaluación de las dos temporadas es a posteriori: los mapas usan la previsión de cada víspera, pero se generaron después y no se publicaron día a día. La escala absoluta se calibró con 250 días de temporada, sin datos de diciembre a abril, y su referencia debe ampliarse con cada día publicado. Y la cobertura se limita a la Península y Baleares, sin Canarias, con datos de 2026 hasta el 2 de septiembre.

Como conclusión, un modelo se optimiza para la pregunta que define su conjunto de entrenamiento. Esa pregunta la determinan la elección de positivos y negativos, no la intención de quien lo entrena. Un acierto alto sobre un conjunto de prueba construido con el mismo diseño que el de entrenamiento no garantiza nada sobre el uso previsto. Por ello, en la segunda iteración se evaluó cada día con la misma verdad con la que se entrena.

La utilidad del resultado se aprecia en la temporada completa de 2025 con el r10. Con un radio operativo de 6 km, se cubrió el 44 % de los incendios vigilando cerca del 10 % del territorio. Es un resultado notable en un fenómeno en el que, en verano, arden entre 2 y 7 celdas de cada 100,000 al día. Esa cobertura permite concentrar la vigilancia en las zonas señaladas, por ejemplo con visión artificial desde cámaras o drones. Permite también avisar a la población y desplegar recursos de forma preventiva, y reducir así el impacto económico, social y humano de los incendios forestales.

El código, con cada cifra enlazada al script que la produjo, está disponible en el repositorio (anexo D).

Anexos

Los anexos amplían la sección en cuatro aspectos: los datos, las alternativas evaluadas, la escala del mapa y la puesta en producción. Cada cifra procede de un fichero generado por un script del repositorio (anexo D); el documento [docs/TRAZABILIDAD.md](#) indica cuál.

A Datos y variables

A.1 Fuentes

La tabla 2 recoge las fuentes empleadas y la fase del trabajo en la que se usó cada una. Las cinco primeras son las que describe el apartado de datos de la sección. Las demás aportaron variables del territorio, la meteorología de la primera puesta en producción o una segunda referencia durante el desarrollo.

Tabla 2. Fuentes de datos, resolución y uso en el trabajo.

Fuente	Qué aporta	Resolución y periodo	Uso
IberFire	261 variables diarias: meteorología, vegetación, relieve, usos del suelo, población y carreteras	1 km; 2008–2024; 29 GB	Variables de entrenamiento de los dos modelos
EGIF (vía Civio)	Punto y fecha de inicio de cada incendio	Registro consolidado hasta 2020	Etiqueta del primer modelo: 19,561 pares celda-día de 2015 a 2020
EFFIS	Perímetros de superficie quemada cartografiados por satélite	Incendios de al menos 5 ha; 2008–2026	Etiqueta del segundo modelo y referencia de todas las evaluaciones
ERA5-Land	Reanálisis meteorológico	Unos 9 km; 5,605 nodos sobre España	Meteorología observada en servicio, hasta siete días antes
IFS (vía Open-Meteo)	Previsión meteorológica	Los mismos nodos; hasta el día siguiente	Meteorología del día y del siguiente; entradas de la reproducción
AEMET	Observación horaria	687 estaciones; verano de 2026	Meteorología de la producción del primer modelo
FIRMS (NASA)	Focos térmicos del sensor VIIRS	Punto; casi tiempo real	Fuego reciente en el entorno de la celda
Partes del MITECO	Incidentes con medios del Estado	Municipio; diario	Segunda referencia durante el desarrollo
Complementarias	Carreteras, población, usos del suelo CORINE y rayos	1 km	Variables del territorio

FIRMS es el *Fire Information for Resource Management System*; VIIRS, el *Visible Infrared Imaging Radiometer Suite*; CORINE (*Coordination of Information on the Environment*), el inventario europeo de usos del suelo.

Antes de construir ninguna variable se comprobó el origen de la meteorología del cubo. Es ERA5-Land remuestreado: las correlaciones con el reanálisis nativo están entre 0.987 y 0.998, sin sesgo. Se encontraron dos excepciones que condicionan el servicio. La precipitación del cubo está dividida por un factor de 2.02, y su FWI solo se reproduce con las condiciones de las 13 UTC (tiempo universal coordinado). La cadena de servicio calcula el FWI a esa misma hora y aplica el mismo factor.

A.2 Variables

Los dos modelos usan las mismas 46 variables por celda y día, agrupadas en seis familias (tabla 3). Todas las ventanas temporales terminan el día anterior al que se predice, salvo las que se describen como «del día».

Tabla 3. Las 46 variables del modelo servido y del r10, por familias.

Familia	Variables	N.º
Meteorología del día	Temperatura máxima y mínima, humedad relativa mínima, viento máximo, precipitación, déficit de presión de vapor máximo, temperatura de la superficie terrestre, FWI absoluto, FWI en percentil respecto a la historia de la celda y anomalía tipificada del FWI	10
Meteorología acumulada	Precipitación de 7, 15 y 30 días; FWI medio de 7, 15 y 30 días y máximo de 7 días; medias de 7 días de humedad mínima, temperatura máxima y viento máximo; días sin lluvia	11
Vegetación y suelo	NDVI (<i>Normalized Difference Vegetation Index</i>) del día y medio de 30 días, índice de área foliar y humedad superficial del suelo	4
Territorio	Elevación, pendiente, rugosidad, distancia a carreteras y a ríos, densidad de población y seis clases de uso del suelo: bosque, matorral, agrícola, agrícola heterogéneo, artificial y abierto	12
Historial y focos	Incendios a 10 km en el mismo mes de años anteriores; potencia radiativa máxima y número de focos a 50 km en los siete días previos; rayos del día y de siete días	5
Calendario y región	Mes, día del año, festivo y comunidad autónoma	4

El primer modelo se entrenó con 50 variables. Antes de ponerlo en producción se retiraron cuatro recuentos de incendios en la propia celda: a 1 km en 90 días y en toda la historia, y a 10 km en 90 y 365 días. El muestreo en la misma celda introducía en ellas una fuga del orden temporal: el incendio del positivo entraba en el historial de los negativos posteriores de esa celda, y el modelo asociaba un historial vacío con el periodo anterior al fuego. Retirarlas costó 0.015 de AUC-PR (*Area Under the Precision-Recall Curve*). En servicio hay otras dos diferencias con

el entrenamiento, medidas y aceptadas: las variables de satélite del día se sustituyen por su climatología mensual y los rayos se fijan en cero. Juntas cuestan 0.0045 de AUC.

A.3 Dos características de los datos

La figura 4 resume las dos propiedades del fenómeno que más condicionaron el diseño. La primera es la escasez de positivos: en verano arden entre 0.5 y 38 celdas de cada 100,000 al día, según el año, frente al 25 % de positivos del conjunto de la primera iteración. La segunda es la persistencia de la etiqueta de EFFIS. Una celda que arde un día sigue marcada al siguiente con probabilidad 0.51, porque la etiqueta señala días ardiendo y no igniciones. Por ello todas las evaluaciones cuentan solo el primer día de cada celda quemada: en los veranos evaluados quedan 7,301 de las 28,135 celdas-día marcadas.




Figura 4: (a) Celdas-día con fuego por cada 100,000, año completo y verano, en escala logarítmica, frente a la proporción de positivos del primer diseño. (b) Probabilidad de que una celda siga marcada como quemada k días después.

El análisis exploratorio motivó también el FWI en percentil local (figura 5). En los días de incendio, el FWI mediano va de 3 en Asturias y Cantabria a 41 en Andalucía, de modo que ningún umbral absoluto sirve para toda la península. Expresado como percentil respecto a la historia de cada celda, el mismo dato se concentra entre 72 y 92 en las ocho comunidades con más incendios. Añadir el percentil al FWI absoluto aumentó el AUC-PR en 0.042.

Detalle en el repositorio: la descarga y el tratamiento de cada fuente en [01_datos/README.md](#), las 46 variables y su orden en [01_datos/comun/features.py](#) y el análisis exploratorio completo en [02_edu/ANALISIS_CUBO.md](#).




Figura 5: FWI en los días de incendio del periodo de entrenamiento, por comunidad autónoma. (a) Valor absoluto. (b) Percentil respecto a la historia de la propia celda.

B Benchmark y alternativas descartadas

B.1 Los seis modelos en las dos temporadas

La reproducción de 2025 y 2026 comparó seis modelos, fijados en el protocolo antes de ejecutarla: el de producción, el modelo único con tres y con diez negativos por positivo (r10), la pareja formada por un modelo de «dónde» y otro de «cuándo», y cada uno de estos dos por separado. Todos recibieron la previsión de la víspera. La tabla 4 reúne las métricas de ordenación y las operativas.

Tabla 4. Benchmark de la reproducción con la previsión de la víspera. AUC: media por día. Días: porcentaje de días en que el modelo supera a producción. Pctl. ha: percentil medio de las celdas quemadas ponderado por hectáreas. Ha 2 % y ha 10 %: porcentaje de la superficie quemada de la temporada que cayó en el 2 o el 10 % de celdas de mayor riesgo de cada día. Inc. 10 %: incendios de al menos 100 ha con alguna celda en ese 10 %.

Modelo	AUC	Diferencia (IC 95 %)	Días (%)	Pctl. ha	Ha 2 %	Ha 10 %	Inc. 10 %
<i>Temporada 2025: 138 días con fuego, 386,855 ha</i>							
Producción	0.743	—	—	84.6	22.0	59.6	66.9
Único 1:3	0.806	+0.063 [+0.026, +0.102]	61	87.5	28.8	63.6	67.6
r10	0.807	+0.064 [+0.027, +0.101]	60	86.7	26.3	63.0	69.6
Pareja	0.794	+0.051 [+0.024, +0.079]	60	90.2	32.3	72.4	73.0
Dónde solo	0.744	+0.001 [−0.043, +0.046]	43	87.3	27.5	63.0	56.1
Cuándo solo	0.686	−0.057 [−0.071, −0.043]	24	79.1	16.1	49.6	56.8
<i>Temporada 2026: 86 días con fuego, 267,566 ha</i>							
Producción	0.658	—	—	68.4	11.5	24.7	40.6
Único 1:3	0.757	+0.099 [+0.058, +0.141]	69	76.5	5.9	25.1	59.4
r10	0.762	+0.104 [+0.065, +0.144]	67	77.9	7.1	37.0	62.3
Pareja	0.716	+0.058 [+0.025, +0.089]	58	74.6	2.2	23.7	58.5
Dónde solo	0.701	+0.043 [−0.008, +0.094]	55	68.6	1.1	11.3	39.6
Cuándo solo	0.614	−0.044 [−0.064, −0.025]	28	67.2	6.1	22.5	31.1

La figura 6 muestra la distribución del AUC día a día que hay tras esas medias. En 2025 la mediana del r10 es 0.844 y la de producción 0.797, pero la diferencia se concentra en la mitad baja: el primer cuartil de producción es 0.621 frente a 0.736 del r10, y producción queda por debajo del azar 16 días frente a 7. En 2026 se repite el patrón con más margen: medianas de 0.799 y 0.688, primer cuartil de 0.690 y 0.517, y 19 días bajo el azar frente a 3. La ventaja del r10 procede de los días en que producción ordena peor.




Figura 6: AUC dentro del día de los seis modelos en los días con fuego de cada temporada, con la previsión de la víspera. Caja: cuartiles y mediana; bigotes: 1.5 veces el rango intercuartílico; puntos: días fuera de ese rango. La cifra sobre cada caja es la media, la misma de la tabla 4. La línea de puntos es el azar.

En ordenación, los dos modelos únicos encabezan las dos temporadas y empatan entre sí. La pareja supera a producción, pero queda por debajo del modelo único. El modelo de «dónde» por separado no se distingue de producción, y el de «cuándo» queda por debajo. Un modelo único que recibe territorio y meteorología a la vez ordena mejor que la combinación de dos modelos especializados.

Las métricas de superficie no siempre siguen al AUC. En 2025 la pareja situó más hectáreas que el r10 en el 2 y en el 10 % de celdas de mayor riesgo. En 2026 producción situó más hectáreas en el 2 % (11.5 frente a 7.1 %), aunque el r10 lo superó en el 10 % (37.0 frente a 24.7 %) y en incendios de al menos 100 ha (62.3 frente a 40.6 %). La superficie de 2026 se concentra en pocos días: sin el 23 de julio, que sumó 21,348 ha, la captura de producción en el 2 % baja del 11.5 al 4.8 %.

B.2 Territorio vigilado y superficie cubierta

La métrica que más interesa a un gestor es la parte de la superficie quemada que cae dentro de la zona señalada, en función del tamaño de esa zona. La tabla 5 la recoge para el r10. El lift es el cociente entre el porcentaje de hectáreas dentro de la zona y el porcentaje de territorio vigilado; un lift de 1 equivale a señalar celdas al azar.

Tabla 5. Captura del r10 según el territorio vigilado cada día. Hectáreas: superficie quemada que cayó en la zona vigilada, redondeada a la centena. Inc.: incendios de al menos 100 ha con alguna celda dentro.

Vigilado	2025 (386,855 ha)				2026 (267,566 ha)			
	Ha (%)	Hectáreas	Inc. (%)	Lift	Ha (%)	Hectáreas	Inc. (%)	Lift
1 %	18.6	72,000	23.7	18.6	3.4	9,000	18.9	3.4
2 %	26.3	101,800	32.4	13.2	7.1	19,100	25.5	3.6
5 %	47.5	183,800	53.4	9.5	17.9	47,900	42.5	3.6
10 %	63.0	243,700	69.6	6.3	37.0	99,000	62.3	3.7
20 %	78.7	304,600	83.8	3.9	58.8	157,400	79.3	2.9

En 2025, vigilar el 2 % del territorio cada día habría cubierto el 26.3 % de la superficie quemada, 13.2 veces lo esperable al azar. Ampliar la zona al 10 % habría cubierto el 63.0 % de la superficie y el 69.6 % de los incendios de al menos 100 ha. En 2026 la curva es más plana: el 10 % del territorio cubrió el 37.0 %, con un lift de 3.7 casi constante desde el 1 %. Por encima del 10 %, cada punto de territorio añadido aporta cada vez menos. Estas hectáreas no deben leerse como superficie evitada. Miden cuánto fuego cayó dentro de la zona señalada, es decir, el máximo que una vigilancia reforzada en esa zona podría haber anticipado.

B.3 Alternativas al r10

La tabla 6 resume las pruebas con resultado negativo. En la escalera de negativos, el AUC-PR de validación no sirve para elegir, porque cada variante tiene una proporción de positivos distinta; la métrica que separa las variantes es el percentil ponderado por hectáreas, que mide dónde quedan los incendios grandes. Entrenar solo con verano quita al modelo de «dónde» información sobre qué territorio arde. Apagar las celdas quemadas penaliza porque EFFIS mantiene marcada la celda mientras el incendio sigue activo. Reentrenar con todos los años no alcanzó el criterio fijado: el modelo no mejora con más datos, y la partición original conserva un conjunto de prueba reservado sin coste.

Tabla 6. Alternativas evaluadas y no adoptadas. Diferencia de AUC medio por día con la configuración de referencia de cada prueba.

Alternativa	Resultado
De 1:3 a 1:100 negativos por positivo	AUC de 2026 entre 0.745 y 0.759, del orden del ruido del sorteo (0.004); el percentil ponderado por hectáreas fue máximo con 1:10 (81.9 frente a 79.5 con 1:3) y bajó a partir de 1:30
Entrenar solo con verano (junio a septiembre)	El «dónde» de verano perdió entre -0.011 y -0.041 en cuatro conjuntos de prueba, con la mayor pérdida en 2022; el «cuándo» no cambió
Apagar las celdas quemadas en los 7 a 60 días previos	Entre -0.016 y -0.027 en la temporada de 2026, para producción y para el modelo único, con cualquier ventana
Reentrenar el r10 con 2015–2024 (un 32 % más de positivos)	$+0.0033$ [-0.0042 , $+0.0104$] sobre 224 días; criterio de éxito fijado por escrito antes de ejecutar, no cumplido

Detalle en el repositorio: el protocolo y las tablas completas de la reproducción en [docs/REPLAY_VEREDICTO.md](#), la captura por territorio en [docs/REPLAY_CAPTURA.md](#), las alternativas en [05_iteracion2/README.md](#) y el reentrenamiento con todos los años en [docs/R10_TODOS_LOS_ANIOS.md](#).

C Escala absoluta y cifra del día

Los dos mapas y la cifra que se publican cada día salen de la misma puntuación del r10. El primer mapa la ordena por percentil del día; el segundo la corta en niveles fijos; la cifra sitúa el día entre los de referencia.

C.1 Cortes calibrados sobre el servicio

Los cortes se calcularon primero con los diez años del cubo, de modo que el nivel extremo fuese el 2 % más alto de su historia. Aplicados a los mapas que produce la cadena de servicio, marcaron entre dos y diez veces más celdas en extremo que el cubo en el mismo mes, tanto con previsión como con reanálisis. La causa es el cálculo de las variables de vecindad en servicio (anexo E); la meteorología quedó descartada. Por ello los cortes publicados se obtuvieron de los propios mapas servidos, los 250 días de 2025 y 2026 de la reproducción. La tabla 7 da el significado de cada nivel. El corte de extremo apenas cambió respecto al cubo (0.4058 frente a 0.4066); los de moderado y alto subieron.

Tabla 7. Niveles del r10 con los cortes del servicio, sobre los 250 días de referencia. Una de cada: celdas-día por cada celda quemada. Factor: frecuencia de quema del nivel dividida entre la media.

Nivel	Corte servicio	Corte cubo	Celdas-día (%)	Quemadas	Una de cada	Factor	Ha (%)
BAJO	0	0	30.0	282	132,600	0.08	1.5
MODERADO	0.0060	0.0018	60.0	5,255	14,200	0.71	40.0
ALTO	0.1125	0.0736	8.0	3,609	2,760	3.63	29.5
EXTREMO	0.4058	0.4066	2.0	3,273	760	13.17	29.0

El significado de los niveles varía entre temporadas. Con cortes calculados solo con 2025 y medidos en 2026, el nivel extremo ocupó el 1.1 % de las celdas-día y en él ardió una de cada 2,560, frente a una de cada 550 en 2025. En 2026 la mayor parte del fuego cayó en el nivel alto, con el 42.5 % de las hectáreas. Los cortes deben recalcularse al acumular días servidos, en especial de diciembre a abril, de los que no hay ninguno.

C.2 Cifra del día y semáforo descartado

La cifra del día es el porcentaje de España en nivel extremo, situado entre los 250 días de referencia; en esa referencia la mediana es el 1.5 %, el percentil 90 el 4.6 % y el máximo el 7.2 %. Como separador de los días con incendio grande (al menos cinco celdas nuevas quemadas), la cifra obtuvo un AUC de 0.69 en 2025 y de 0.66 en 2026, frente a 0.74 y 0.44 del calendario. En el cubo, con años que la calibración no usó (2022–2024), obtuvo 0.87 de diciembre a abril y 0.77 de junio a septiembre, frente a 0.61 y 0.71 del calendario. Comparar cada día con los de su mismo mes empeoró el resultado, por lo que la referencia agrupa todos los días.

Antes de la cifra se evaluó un semáforo nacional. La regla retiraba el nivel extremo los días en que el percentil 98 de la puntuación, convertido en probabilidad de día grande con una calibración ajustada en 2015–2021, no llegaba a 0.155. Aplicada a los diez años del cubo, de diciembre a abril dejó sin extremo el 44.0 % de los días y perdió el 6.2 % de los días grandes. En verano apagó el extremo en el 55.5 % de los días y en el 31.7 % de los días grandes, porque en verano el percentil 98 se concentra justo por debajo del umbral. Fuera del periodo de calibración (2022–2024) perdió el 34.6 % de los días grandes de verano. En la reproducción de 2026 perdió el 54.4 %, que sumaban el 60.4 % de la superficie quemada. Se compararon cuatro variantes (todo el año, fuera de verano, solo de diciembre a abril y con umbral por época) y ninguna se adoptó. El semáforo reduce a dos valores la misma señal que ya resume la cifra del día, y en verano su coste no se compensa. Un aviso limitado a los meses de invierno queda como línea futura, pendiente de calibrarlo con mapas servidos de esa época. El detalle está en [07_produccion/escala_y_cifra/README.md](#).

La puntuación no es una probabilidad por celda. Calibrada con regresión isotónica sobre todas las celdas-día del cubo, la celda de mayor riesgo en diez años no supera el 1.6 % de probabilidad de arder ese día, y esa probabilidad depende de la intensidad de la temporada (anexo E). Por eso el mapa publica niveles y no probabilidades.

Detalle en el repositorio: los cortes, la referencia y el semáforo evaluado en [07_produccion/escala_y_cifra/README.md](#) y la calibración en el cubo en [05_iteracion2/56_calibracion/README.md](#).

D Repositorio, reproducibilidad y cadena diaria

El código y la documentación están en un repositorio público, github.com/JuanUtrilla/tfm-riesgo-incendios. Las carpetas siguen el orden de esta memoria (tabla 8) y cada una tiene un fichero README.md que indica qué hace cada script y para qué se usó. En total son 181 scripts de Python.

Tabla 8. Organización del repositorio y dónde ampliar cada parte de la memoria.

Carpeta	Contenido
00_marco/	Hilo de la memoria, glosario y diagrama de las dos iteraciones
01_datos/	Descarga y tratamiento de las fuentes, común a los dos modelos; las 46 variables en comun/features.py
02_eda/	Análisis exploratorio del cubo y del conjunto de entrenamiento
03_iteracion1/	Etiqueta EGIF, muestreo, entrenamiento y puesta en producción del primer modelo
04_bisagra/	Diagnóstico de la diferencia entre el acierto de laboratorio y el de operación
05_iteracion2/	Segundo modelo, alternativas del anexo B y calibración en el cubo
06_comparacion/	Comparación sobre los mismos días y reproducción de 2025 y 2026 (docs/REPLAY_VEREDICTO.md)
07_produccion/	Cadena diaria, escala del servicio y cifra del día
docs/	TRAZABILIDAD.md (cifra a cifra, script y fichero de origen), PROCEDENCIA.md , LIMITACIONES.md y bitácora
muestras/	Recorte de julio de 2026 (48 MB) para ejecutar la rama de servicio sin descargar el cubo

La tabla 9 indica, para cada parte de la memoria, el fichero del repositorio que la amplía. Las rutas son relativas a <https://github.com/JuanUtrilla/tfm-riesgo-incendios/blob/main/>.

Tabla 9. Dónde ampliar cada parte de la memoria.

Parte	Fichero
Objetivo, hilo y glosario	00_marco/README.md · 00_marco/GLOSARIO.md
Datos y análisis exploratorio	01_datos/README.md · 02_eda/README.md
Primer modelo y evaluación en operación	03_iteracion1/README.md · 03_iteracion1/MODELO_B_BITACORA.md
Diagnóstico: por qué el 0.89 no medía lo que hacía falta	04_bisagra/README.md
Segundo modelo, alternativas y calibración	05_iteracion2/README.md · 05_iteracion2/56_calibracion/README.md
Reproducción de 2025 y 2026	06_comparacion/README.md · docs/REPLAY_VEREDICTO.md
Mapa diario, escala, cifra y verificación	07_produccion/README.md · 07_produccion/escala_y_cifra/README.md
Cifra a cifra: script y fichero de origen	docs/TRAZABILIDAD.md
Procedencia y huella MD5 de cada fichero	docs/PROCEDENCIA.md
Limitaciones y bitácora	docs/LIMITACIONES.md · docs/BITACORA.md

D.1 Trazabilidad y reproducibilidad

Tres decisiones permiten comprobar las cifras. En primer lugar, los scripts son copias literales de los que produjeron los resultados; `docs/PROCEDENCIA.md` registra el origen y la huella MD5 de cada uno, y solo se adaptaron las rutas de cuatro módulos comunes. En segundo lugar, `docs/TRAZABILIDAD.md` enlaza cada cifra de la memoria con el script que la produjo, el fichero donde quedó escrita y los datos que necesita. Por último, el entorno está fijado en `environment.yml` (conda, XGBoost 3.2.0) y, para la cadena diaria, en `requirements_gh.txt`.

Todos los entrenamientos citados se repitieron en una copia aislada el 2 de septiembre de 2026. Las métricas coincidieron y los modelos resultantes fueron idénticos byte a byte a los originales. El modelo servido en 2026, que se había reentrenado de forma interactiva, se reconstruyó árbol a árbol a partir de la receta documentada.

Los datos crudos no están en el repositorio: el cubo IberFire ocupa 29 GB y los entrenamientos lo necesitan. La carpeta `muestras/` contiene un recorte de julio de 2026 con el que la rama de servicio se ejecuta en un ordenador personal con cuatro órdenes:

```
source entorno.sh
python 07_produccion/riesgo_hoy.py
python 07_produccion/dos_riesgo_hoy.py
python 07_produccion/mapas_hoy_manana.py
```

D.2 Cadena diaria

El mapa se publica cada madrugada desde GitHub Actions, el servicio de ejecución automática de GitHub, que no tiene acceso al cubo. La figura 7 muestra los pasos. La corrida dura alrededor de una hora y cuarto, casi toda en la descarga del reanálisis y de la previsión. El estado que se conserva entre corridas (el reanálisis acumulado y los mapas recientes) se guarda en una publicación del propio repositorio. Cada día se generan dos imágenes, para hoy y para mañana, y un fichero JSON con la cifra del día. Las imágenes de hoy aparecen en la portada del repositorio y los diez últimos días quedan en la carpeta `publicado/`. Durante el verano de 2026 la misma cadena corrió en un repositorio previo y publicó también los mapas de los otros candidatos.

La referencia con la que se verifica el mapa se conoce después de publicarlo: el parte del MITECO del día D se publica el D+1 y los perímetros de EFFIS tardan entre seis y nueve días. Por eso cada corrida redibuja también los mapas de los veinte días anteriores con lo que ya se conoce, sin modificar el original. De cada fecha quedan dos imágenes: la que se predijo y la misma con los perímetros de EFFIS y los incidentes del MITECO superpuestos. El parte del MITECO solo da el municipio del incidente, así que cada incidente se sitúa en el centroide del municipio, con un error de 5 a 15 km. Se evalúa con un radio de 10 km, tomando el mejor nivel del mapa dentro de ese círculo. Es el mismo parte que alimenta el módulo de consulta del sistema, de modo que el documento que lee el asistente es el que verifica el mapa. En los trece primeros días de septiembre de 2026, con el nivel extremo entre el 0.2 y el 1.6 % de España, cayó en él el 22 % de las celdas quemadas del día y el 37 % de los incidentes del MITECO; en alto o extremo, el 66 y el 78 %.




Figura 7: Pasos de la cadena diaria. En cursiva, la fuente o el producto de cada paso. CDS es el *Climate Data Store* de Copernicus.

E Limitaciones

La tabla 10 resume las limitaciones conocidas, con su efecto medido y su consecuencia. La primera se comenta a continuación.

Tabla 10. Limitaciones conocidas del trabajo.

Limitación	Efecto medido	Consecuencia
Evaluación a posteriori	Mapas generados en septiembre de 2026 con las entradas de cada víspera	Mitigada por el protocolo escrito antes de ejecutar
Defecto del viento en el ranking por estaciones	FWI hundido en el 16.3 % de las estaciones-día del verano de 2026	Afecta a las cifras de operación del primer modelo, no a la reproducción
Filtro de vecinos distinto al entrenar y al servir	Tres variables entre un 36 y un 54 % mayores en servicio	Cambia la escala, no el orden; afecta igual a todos los modelos
Variables de satélite del día D	Un 4 % de la importancia del r10	Se sustituyen por climatología en servicio
Ruido del sorteo e intervalos	Sorteo: 0.004 de AUC; intervalos 1.35 veces más estrechos que con bloques de 14 días	Los IC son una cota inferior de la incertidumbre
Probabilidad por celda	En julio, del 0.00 % (2023) al 12.76 % (2022) en la franja más alta	Se publica el nivel, no la probabilidad
Escala absoluta en servicio	Cortes calibrados con 250 días de temporada	Sin datos de diciembre a abril; recalcular al acumular días
Etiquetas	EFFIS omite incendios pequeños y tarda unos 45 días	Las etiquetas de 2026 aún pueden cambiar
Cobertura	Península y Baleares; 2026 hasta el 2 de septiembre	Sin Canarias, Ceuta ni Melilla

Evaluación a posteriori. Los mapas de la reproducción usan la previsión disponible la víspera de cada día, pero se generaron todos a la vez en septiembre de 2026, cuando los perímetros ya se conocían. Un modelo puntuado así no tiene el mismo valor que uno publicado antes del día, porque nada impide en principio elegir los modelos o las métricas a la vista del resultado. Tres hechos lo mitigan. El protocolo se registró por escrito antes de ejecutar nada; los seis modelos se presentan siempre; y la evaluación de 2026 con reanálisis, hecha antes y por otra vía, apunta en la misma dirección (+0.112, IC95 [+0.074, +0.151]).

Detalle en el repositorio: las limitaciones con su medida en [docs/LIMITACIONES.md](#) y el defecto del viento y el filtro de vecinos en [04_bisagra/README.md](#).