

Predicción diaria del riesgo de incendio: dónde y cuándo

Borrador de la sección de machine learning de la memoria conjunta. Objetivo: 5 páginas, tono divulgativo, sin fundamentos ni código. Escrito el 07/09/2026 a partir de docs/TRAZABILIDAD.md, docs/REPLAY_.md, calibracion_si/RESULTADOS_05SEP.md y los READMEs por capítulo. Todas las cifras están trazadas al final, en «Notas para el autor» (no van a la memoria). Los [FIG n] y [TAB n] marcan el hueco de cada figura o tabla.*

1. La pregunta, y el resultado en un párrafo

La España peninsular cabe en 498.530 celdas de un kilómetro de lado. La pregunta que responde este módulo es, cada mañana, **cuáles de esas celdas van a arder hoy**. No es un mapa de «zonas propensas», que sería el mismo todos los días, sino un ranking diario: el producto es una ordenación de las celdas de más a menos peligro, y lo único que importa de ella es si las que efectivamente ardieron estaban arriba.

El camino hasta ahí no fue en línea recta, y esa es la parte del trabajo que más vale la pena contar. Un primer modelo alcanzó un acierto del 0,89 en su propio banco de pruebas y, puesto a funcionar cada día y medido contra lo que de verdad se quemó, cayó a 0,56-0,64. La causa no era que el modelo estuviera mal ajustado ni que la meteorología en tiempo real fuera peor que la de entrenamiento: era que **el conjunto de datos con el que se entrenó hacía otra pregunta**. Corregido eso, y reevaluado sobre las temporadas completas de 2025 y 2026, el nuevo modelo pasa de 0,74 a 0,81 en 2025 y de 0,66 a 0,76 en 2026, y lo hace prediciendo a un día vista con la misma precisión que si supiera el tiempo que va a hacer.

Este módulo es el «antes» del sistema conjunto: anticipa el riesgo que la visión por computador confirma y que el asistente sobre los partes del MITECO permite consultar.

2. Con qué se construye

Cuatro fuentes, y conviene tener claro qué aporta cada una porque el giro del trabajo está en la diferencia entre dos de ellas.

Tabla 1. Las cuatro fuentes de datos y el papel de cada una. La diferencia entre EGIF (puntos de ignición) y EFFIS (perímetros quemados) es la que separa las dos iteraciones.

Fuente	Qué es	Para qué se usa
IberFire	Un «cubo» de datos abierto (Tekniker / UPV-EHU) con 261 variables diarias para cada celda de 1 km desde 2008 hasta 2024: tiempo, vegetación, terreno, usos del suelo, población, carreteras	De aquí salen casi todas las variables del modelo
EGIF	El registro oficial de incendios del Ministerio: una fila por incendio con su fecha y un punto GPS de inicio	La etiqueta del primer modelo
EFFIS	Los perímetros de superficie quemada que Copernicus cartografía por satélite	La etiqueta del segundo modelo, y la verdad contra la que se juzgan los dos
ERA5-Land / IFS	El reanálisis meteorológico europeo (lo que pasó) y la previsión del ECMWF (lo que va a pasar)	Entrenar con lo que pasó; servir cada día con lo que va a pasar

El modelo ve **46 variables** por celda y día. Dichas en castellano, son cuatro familias: *qué tiempo hace* (temperatura, humedad, viento, lluvia de hoy y de los últimos 7, 15 y 30 días, y el índice de peligro FWI), *qué hay en la celda* (proporción de bosque y matorral, pendiente, altitud, distancia a carreteras, población), *qué ha ardido cerca antes*

(incendios en 1 y 10 km en los últimos meses y años, focos térmicos detectados por satélite en la última semana) y *qué día es*. La lista completa está en el anexo A.

Una de ellas merece una línea porque es una aportación propia del trabajo: el FWI no se usa solo en valor absoluto, sino como **percentil de la propia celda**. Un FWI de 40 es rutina en Almería y excepcional en Asturias; lo que predice el fuego no es el número, sino lo raro que es ese número *ahí*. Esa variable sola aporta +0,042 de acierto.

3. El primer modelo, y por qué falló al salir a la calle

El primer modelo se construyó como se construyen casi todos los de la literatura. Los positivos son los 19.561 incendios del registro EGIF entre 2015 y 2020, cada uno en su celda y su fecha. Los negativos se sortean tomando **la misma celda en otros días** en que no ardió, tres por cada positivo. Se entrena un XGBoost, se afina con 2021 y se prueba con 2022 —el peor año de la década, con Losacio y Sierra de la Culebra dentro—, y da un AUC de **0,89**. Un control con etiquetas barajadas confirma que no hay fugas.

Con ese resultado se puso en producción en julio de 2026: cada mañana descarga la observación de 687 estaciones de AEMET, calcula las 46 variables, puntúa y publica un ranking nacional y un mapa de riesgo para hoy y mañana. Lleva desde entonces corriendo sin interrupción, y esa serie sellada es lo que permite todo lo que viene después.

Y entonces se midió. Contra los perímetros de EFFIS, contra los partes diarios del MITECO y contra los focos térmicos de satélite, el acierto diario del modelo en producción estuvo entre **0,56 y 0,64**. Un índice tan simple como el percentil local del FWI, sin modelo, sacaba 0,70.




Figura 1. Las dos iteraciones del trabajo y el diagnóstico que las separa. Lo que cambia entre ellas no son las fuentes ni las 46 variables, sino qué se toma como positivo, qué como negativo y contra qué

verdad se valida. La iteración 1 se puso en producción y es el grupo de control contra el que se mide todo lo demás.

Había tres sospechosos, y los dos primeros se descartaron con números antes de llegar al tercero:

1. **¿Está mal medido?** No: tres verdades independientes —satélite, cartografía y partes oficiales— cuentan lo mismo.
2. **¿Es la meteorología?** El modelo se entrenó con el reanálisis del cubo y se sirve con estaciones. Hay diferencias reales —el reanálisis «llueve» 8 mm más al mes, y eso baja el FWI 10 puntos—, pero al cuantificarlas no explican la caída. Tampoco explica nada lo que cambia entre entrenar y servir: sustituir las variables de satélite por su climatología cuesta 0,0045.
3. **Es la pregunta.** Al sortear los negativos en *la misma celda otros días*, el 98,8 % de las celdas del conjunto de entrenamiento tenían exactamente un 25 % de días positivos. El modelo no podía aprender qué celda es más peligrosa que otra, porque todas tenían la misma proporción de fuego; solo podía aprender **qué día** es peligroso. Respondía a «¿es hoy un día malo en esta celda?», y en operación se le preguntaba «¿cuál de las 498.530 celdas arde hoy?».

La prueba definitiva es que la métrica de laboratorio era ciega a la diferencia. Se construyeron dos conjuntos de entrenamiento, uno con negativos de la misma celda y otro con negativos del mismo día. Medidos cada uno con su propio banco de pruebas, los dos dan 0,92. Medidos **dentro de cada día**, que es como se usan, dan 0,744 y 0,828. La segunda medida es la que había que haber hecho desde el principio, y es la lección del trabajo.

4. El segundo modelo: cambiar la pregunta, no el algoritmo

La segunda versión cambia exactamente dos cosas y deja todo lo demás igual: las mismas 46 variables, el mismo algoritmo con los mismos parámetros, la misma malla.

- **Los negativos son otras celdas del mismo día.** Así el modelo aprende a comparar celdas entre sí, que es lo que se le pide.
- **La etiqueta es la superficie quemada de EFFIS**, la misma con la que se juzga. Entrenar con puntos de ignición y evaluar con perímetros era comparar dos cosas distintas: solo el 15 % de las igniciones de 25-100 ha coincide celda a celda con un perímetro del mismo día.

Se probaron varias configuraciones —un modelo único frente a la pareja de un modelo de *dónde* (fijo) por uno de *cuándo* (diario), y distintas cantidades de negativos por positivo— y se seleccionó el **modelo único con diez negativos por positivo**, «r10» en adelante. No es que las demás fueran mucho peores: la cantidad de negativos mueve el acierto medio apenas +0,01, del orden del azar del sorteo; donde el r10 marca la diferencia es en los incendios grandes, que es donde importa. El detalle de esas pruebas, incluidas las que salieron mal (entrenar solo con verano empeora; añadir una capa de «ya quemado» empeora), está en el anexo B.

5. Resultados: dos temporadas enteras, a un día vista

Para comparar con justicia hay que poner a los dos modelos ante los mismos días, la misma meteorología y la misma verdad. Se hizo reproduciendo día a día las temporadas de 2025 y 2026 (del 1 de junio al 1 de noviembre y al 2 de septiembre respectivamente), alimentando a ambos con **la previsión que estaba disponible la víspera** y juzgándolos con los perímetros de EFFIS. El protocolo se escribió y se registró antes de ejecutar nada.

Tabla 2. El veredicto del replay: acierto medio por día (AUC dentro del día) de producción y del r10, alimentados con la previsión de la víspera y juzgados con los perímetros de EFFIS. La diferencia es la media pareada día a día, con intervalo bootstrap al 95 %.

Temporada	Días con fuego	Hectáreas	Producción	r10	Diferencia (IC 95 %)	Días que gana el r10
2025	138	387.000	0,743	0,807	+0,064 [+0,027, +0,101]	60 %
2026	86	268.000	0,658	0,762	+0,104 [+0,065, +0,144]	67 %

Tres lecturas para quien no quiera mirar los decimales:

La mejora es consistente y no es ruido. El intervalo de confianza no toca el cero en ninguna de las dos temporadas, y el r10 gana en dos de cada tres días. Es mayor en 2026, la temporada en que producción lo pasó peor.

Predecir no cuesta nada. Cada día se calculó dos veces: con la previsión de la víspera y, a posteriori, con el tiempo que realmente hizo. La diferencia es de $-0,003$, indistinguible de cero. El modelo no depende de acertar el tiempo al detalle; depende de saber dónde está el combustible y cuánto lleva seco.

Es un mapa para vigilar, no una alarma por celda. Que arda una celda concreta un día concreto es rarísimo: una de cada diez mil. En el 2 % más alto del mapa del r10 esa tasa se multiplica por doce, y si se mira a 6 km alrededor —la escala a la que se despliegan medios—, ese 2 % cubre el 44 % de los incendios de 2025 vigilando el 10 % del territorio. Producción cubría el 29 % con el 6,6 %. El mapa dice dónde mirar, no dónde va a arder.




Figura 2. El 7 de agosto de 2026 (44.672 ha quemadas, el segundo día de la temporada) según producción y según el r10, ambos en percentil del día, y la resta entre los dos en puntos de percentil. Los círculos negros son las celdas que EFFIS cartografió como quemadas ese día. El r10 sube la cornisa cantábrica y Galicia y baja el interior sur: aprendió dónde se quema territorio, no solo dónde empiezan los incendios.


Además del replay, el sistema **corre en vivo desde el 21 de agosto** en GitHub Actions: cada madrugada descarga la previsión, publica los mapas de ambos modelos y los puntúa contra tres jueces independientes —EFFIS, el parte del MITECO y el ranking por estación de producción—. A 7 de septiembre acumula entre 8 y 13 días según el juez; los candidatos van por delante en EFFIS y MITECO, pero con tan pocos días los intervalos siguen cruzando el cero. Se cuenta como lo que es: una validación operativa en curso, no el veredicto.

6. Del ranking al producto: dos capas


El modelo da a cada celda una nota, y el mapa se pintaba por **posición en el ranking del día**: el 2 % más alto en rojo, el 8 % siguiente en naranja. Eso tiene un defecto que se ve enseguida en cuanto sale del verano: el ranking siempre tiene un primero, así que un martes de febrero sale con tanto rojo como el 15 de agosto, aunque la nota de esa celda «roja» sea veinte veces menor.

La solución tiene dos piezas. La primera es fijar los colores **en la escala de la nota**, no en la del día: se pasaron los modelos por los diez años del cubo —3.653 días— y se anotó a partir de qué nota se entra en el 2 % más alto *de toda la historia*. Con esa regla el rojo significa algo concreto: en diez años, de cada 800 celdas pintadas de EXTREMO ardió una, 36 veces más que el promedio; en las de BAJO, cinco en toda la década. Pero la escala absoluta sola no apaga el mapa de invierno: las variables que fijan *dónde* (bosque, pendiente, historial) no cambian con la estación, y las mismas celdas superan el corte en enero y en agosto. Hace falta la segunda pieza, un **semáforo nacional**: si la nota más alta de España ese día no supera el umbral que en la historia separa los días con incendio grande, hoy no es un día de fuego y el mapa no se pinta. Con esa puerta, en invierno el 44 % de los días quedan sin rojo y solo se pierde el 6 % de los días grandes.


13 de agosto de 2025 · percentil del día
EXTREMO: 2.0 % de las celdas



13 de agosto de 2025 · escala absoluta
EXTREMO: 4.8 % de las celdas



29 de octubre de 2025 · percentil del día
EXTREMO: 2.0 % de las celdas



29 de octubre de 2025 · escala absoluta
EXTREMO: 0.3 % de las celdas




Figura 3. El mismo modelo (r10) pintado de dos maneras en un día de pleno verano (13 de agosto de 2025, arriba) y en uno fuera de temporada (29 de octubre de 2025, abajo). Izquierda: niveles por percentil del día, que reparten el 2 % de EXTREMO cada día sin excepción. Derecha: cortes fijos en la

escala de la nota, aprendidos de diez años de historia, y el semáforo nacional: el 29 de octubre no supera el umbral y el mapa se apaga.

Al comprobarlo se aprendió algo que no estaba previsto. Ese semáforo, fijado con datos de 2015-2021, funciona sin retocar en 2025 y 2026. Pero **no tiene habilidad en verano**: de junio a septiembre casi todos los días pasan del umbral, y decir «hoy es peligroso» en julio no añade nada al calendario. Donde sí aporta es en invierno y primavera, cuando distingue el día raro en que arde la cornisa cantábrica del resto. Por eso el producto final tiene dos capas: el semáforo dice *si* hoy hay que mirar el mapa, y el mapa dice *dónde*. En verano el semáforo está siempre en rojo y manda el mapa; en invierno está casi siempre en verde y evita el mapa rojo falso.

Una precisión que conviene dejar escrita: la nota del modelo **no es una probabilidad**. Un 0,80 no significa «80 % de que arda». Es una puntuación para ordenar celdas y compararla con umbrales, y así se presenta siempre: como nivel, nunca como porcentaje.

7. Límites, y lo que se aprendió

Cuatro límites que el lector debe conocer:

- **La evaluación de dos temporadas es a posteriori.** Los mapas de 2025 y 2026 se generaron con la previsión de cada víspera, pero se generaron *después*, no sellados día a día. Lo sellado es la cadena en vivo, y esa aún no tiene días suficientes. Las dos medidas dicen lo mismo con distinta fuerza, y se reportan ambas.
- **La nota no es calibrable como probabilidad** por celda, y el sistema se presenta como ranking y niveles.
- **El sistema en producción sirve una versión con un defecto conocido** en el cálculo del viento, detectado en agosto y no corregido a propósito para no romper la comparación en marcha. Está cuantificado en el anexo E.
- **Cobertura:** Península y Baleares, sin Canarias; datos de 2026 hasta el 2 de septiembre.

Y la lección, que es lo que este módulo aporta más allá de un mapa:

Un modelo se optimiza para la pregunta que define su conjunto de entrenamiento, y esa pregunta la fija la elección de positivos y negativos, no la intención de quien lo entrena. Un acierto alto sobre un banco construido con el mismo diseño que el entrenamiento no demuestra nada sobre el uso previsto. La comprobación que lo detecta —evaluar dentro de cada día, con la misma verdad con la que se va a juzgar el sistema— es barata y debería hacerse antes de entrenar, no después de dos meses en producción.

El código completo, con cada cifra de esta sección enlazada al script que la produjo, está en el repositorio `tfm-riesgo-incendios` (anexo F).

Notas para el autor (no van a la memoria)

Presupuesto. ~2.450 palabras + 2 tablas + 3 figuras ≈ 5-5,5 páginas a 11 pt. Si sobra, el §5 (resultados) es el último que se recorta; §2 y §4 los primeros.

Trazabilidad de cada cifra (ver docs/TRAZABILIDAD.md):

Cifra	Origen
498.530 celdas, 261 variables, 2008-2024	BORRADOR_memoria_ML.md §1.1, 02_eda/ANALISIS_CUB0.md
46 variables; +0,042 del percentil local	features.py; 35_ablaciones/ablacion_features.py
19.561 incendios EGIF 2015-20; split v4; AUC 0,89 (0,8906 test 2022)	muestrear_dataset_v4.py, T/dataset/metricas_v4.json
687 estaciones; 0,56-0,64; FWI percentil 0,70	04_bisagra/41_* (0,702 en serie D0)
+8 mm/30 d; -0,0045	42_no_es_la_meteo/experimento_b_era5.py; 43_*
98,8 %; 0,92 / 0,744 vs 0,828; 15 % EGIF-EFFIS	44_*, dos_04_analisis.py
Ratio: +0,006...+0,017, ruido 0,004-0,005	dos_18_ratio.py, LIMITACIONES.md §4
Tabla 2 (replay)	docs/REPLAY_VEREDICT0.md (2025_ifs, 2026_ifs)
Coste previsión -0,003	REPLAY_VEREDICT0.md, bloques ifs_menos_reanalisis
Lift ×12, 44 % / 10 % vs 29 % / 6,6 %	REPLAY_PRECISION.md, REPLAY_COBERTURA.md
Jueces a 7-sep	publicado/historico_veredictos.csv (run 34099321965)
3.653 días; 1 de cada 800 (lift 35,6×); 5 en BAJO; 44 % / 6,2 %; sin habilidad en verano	05_iteracion2/56_calibracion/README.md; calibracion_si/RESULTADOS_05SEP.md §2, §4, §6
Bug del viento; 21-ago; 5 días perdidos	LIMITACIONES.md §1; PENDIENTE.md

Decisiones asumidas en el texto (cambiar si no procede): 1. Titular = replay, no los 74 días retrospectivos. 2. Ventana 2026 cerrada el 02-sep (opción A del plan del 07/09). 3. Modelo propuesto = r10 para el dónde; la pareja para el semáforo se menciona sin nombrarla («semáforo nacional»). 4. Los jueces en vivo se citan con fecha; actualizar el párrafo al cierre. 5. El 21-ago excluido del juez EFFIS: no se menciona en el texto, va al anexo E.

Figuras propuestas: - FIG 1: ya existe (figs/fl_iteraciones.png). - FIG 2: existe el mapa de seis paneles de dos_riesgo_hoy.py; recortar a tres (producción, r10, resta). - FIG 3: nueva. Un día de invierno del replay pintado con CORTES_PCTL y con los cortes absolutos de dos_27. Hay que generarla.

Anexos referenciados: A variables y fuentes · B ablaciones y resultados negativos · C jueces en vivo al cierre · D calibración del semáforo (BSS/SEDI por régimen, cortes absolutos) · E incidentes con efecto en los números (fuga FIRMS, días perdidos 27-31/08, mapa del 21-ago, bug del viento) · F guía del repositorio.