

1 Modelado predictivo del riesgo diario de incendio

El componente que se describe aquí contesta una pregunta operativa estrecha: de las 498.530 celdas de un kilómetro en que queda dividida la España peninsular, cuáles van a arder hoy. No es una pregunta de susceptibilidad —qué territorio es propenso al fuego, que se responde con un mapa fijo— sino de ordenamiento dentro de un día concreto. El producto es un ranking diario de celdas y lo único que importa de él es si las celdas que efectivamente ardieron caen arriba. Esa distinción, que parece de matiz, resultó ser el eje del trabajo.

Era necesario porque la parte de este TFM que ya estaba en producción —un modelo entrenado con un muestreo clásico en la literatura de susceptibilidad— alcanzaba un AUC-ROC de 0,89 en su propio conjunto de test y caía a 0,56–0,64 cuando se le pedía ese ranking contra superficie quemada real. La sección documenta por qué ocurre esa caída, qué se descartó antes de dar con la causa, cómo se rediseñó el conjunto de entrenamiento y cuánto se ganó: dos iteraciones completas del mismo problema separadas por un diagnóstico, y una comparación de ambas sobre los mismos días y las mismas fuentes.

El resultado principal, anticipado: la caída no venía del ajuste, ni de la meteorología, ni del desajuste entre entrenamiento y servicio, sino de la especificación —de qué se toma como positivo y, sobre todo, como negativo— y corregirla lleva el AUC dentro del día de la temporada 2026 de 0,647 a 0,759, una diferencia pareada de +0,112 con intervalo de confianza al 95 % [+0,074, +0,151] sobre 74 días. La figura 1 sitúa las dos iteraciones y el diagnóstico que las separa.




Figura 1: Las dos iteraciones del trabajo y la bisagra que las separa. Lo que cambia entre ellas no son las fuentes ni las variables —las 46 del modelo servido de la iteración 1 son las de la iteración 2— sino qué se toma como positivo, qué como negativo y contra qué verdad se valida. La iteración 1 se puso en producción y es el grupo de control contra el que se mide todo lo demás.

1.1 Datos y preparación

El soporte del trabajo es IberFire, un datacubo público de riesgo de incendio para la Península Ibérica: un NetCDF de 30,3 GB con 261 variables sobre una malla de 1.188×920 celdas de un kilómetro (EPSG:3035), paso diario y cobertura 2007–2024. Una fila de entrenamiento es la lectura de todas sus capas en una celda y un día, y de ahí salen 45 de las 46 variables. Su meteorología resultó ser el reanálisis ERA5-Land remuestreado (correlaciones de 0,987 a 0,998 y sesgo nulo), con dos discrepancias que condicionan el servicio: la precipitación viene dividida por un factor de 2,02, y su índice FWI —el Fire Weather Index canadiense, la escala meteorológica de peligro de uso estándar— solo se reproduce con las condiciones de las 13 UTC.

Las etiquetas son el punto delicado, porque hay dos y ninguna contiene a la otra. EGIF registra la ignición como punto con su fecha y su superficie final, y aporta 19.561 pares celda-día entre 2015 y 2020; a partir de 2021 está sin consolidar —888, 226 y 23 registros frente a los varios miles reales—, lo que fija la ventana

temporal de la primera iteración. EFFIS aporta el perímetro de área quemada rasterizado en el cubo como la variable `is_fire`, que marca cada celda que ardió cada día a partir de cinco hectáreas y cubre 2008–2024. Se solapan poco celda a celda y día a día: solo el 2,6 % de los incendios EGIF de 5 a 25 hectáreas tiene `is_fire` activo en su celda ese día, y el 59 % de los mayores de 500. EFFIS es ciego a lo pequeño y sitúa el fuego en el perímetro; EGIF es la ignición pero llega con dos a cuatro años de retraso y nunca podrá juzgar un sistema vivo. Se entrena una iteración con cada una. La prevalencia real explica media sección: en un verano normal arden entre 2 y 6 celdas de cada 100.000 al día, y 38 por 100.000 en el verano récord de 2022.

Las 46 variables se agrupan en cinco bloques: meteorología del día y sus ventanas móviles de 7, 15 y 30 días, con el FWI en valor absoluto, en percentil frente a la climatología de la propia celda y en anomalía tipificada; vegetación y humedad de suelo por satélite; estáticas de terreno y exposición humana, con siete clases de uso del suelo CORINE; historia de fuego y focos activos, con la densidad histórica de incendios a 10 km en el mismo mes y las detecciones FIRMS a 50 km; y calendario. Los focos FIRMS describen el entorno y nunca son etiqueta. La regla que gobierna toda la construcción de variables es que ninguna ventana puede incluir el día que se predice: se escriben con desigualdad estricta —por ejemplo $(vf_d \geq d-7) \ \& \ (vf_d < d)$ para FIRMS— de modo que el día D queda fuera por construcción.

1.2 Análisis exploratorio

La exploración se hizo sobre dos objetos distintos y las dos veces hizo falta: el cubo entero —qué hay en las 498.530 celdas por día antes de muestrear nada— y el conjunto ya muestreado de la primera iteración, restringido al tramo de entrenamiento para que ninguna decisión de diseño se tomara mirando validación o test.

Del cubo salieron los dos números que gobiernan todo lo que viene después (figura 2). El primero es la prevalencia: en un verano normal arden entre 2 y 6 celdas de cada 100.000 al día, y 38 por 100.000 en 2022, el año récord. El conjunto de la primera iteración tenía, por construcción, un 25 % de positivos: cinco órdenes de magnitud por encima. Ese desajuste no es un detalle de calibración, es una pregunta distinta —el modelo aprende a separar igniciones de pseudo-ausencias sorteadas, no a ordenar el territorio de un día— y es lo que anticipa el diagnóstico de la bisagra. El fuego es además un fenómeno concentrado: solo el 2,97 % de las celdas tuvo alguna ignición EGIF en 2015–2020.

El segundo es que la etiqueta persiste. La probabilidad de que una celda que arde hoy siga ardiendo mañana es 0,51; a los tres días 0,23 y a los siete 0,04. `is_fire` marca días ardiendo, no igniciones, y contar los días de arrastre sería puntuarse el mismo incendio siete veces. De ahí que la evaluación con EFFIS use `primer_día` —arde hoy y no ardía ayer—, que deja 7.301 de las 28.135 celdas-día de los veranos evaluados.




Figura 2: Los dos hallazgos del cubo que condicionan el diseño. (a) Prevalencia real de celdas-día con fuego, en escala logarítmica, frente al 25 % de positivos que tenía el conjunto de la primera iteración. (b) Persistencia de la etiqueta: la mitad de las celdas que arden un día siguen ardiendo al siguiente.

La tercera medida del cubo decide cómo se parte. El índice de Moran de las celdas con EFFIS a un kilómetro es 0,81: a esa escala la etiqueta es sobre todo perímetro, celdas contiguas del mismo incendio. Partir al azar infla el AUC en +0,036 frente a partir por bloques de 100 km, así que todas las particiones del trabajo son espaciales o temporales y ninguna aleatoria.

1.3 De la exploración a las variables

La exploración del conjunto muestreado es la que dio forma a las variables. La comparación de medianas entre clases (figura 4) ordena lo que separa: el FWI absoluto, los días sin lluvia y la precipitación acumulada de 30 días se despegan con claridad, mientras la densidad de población y la distancia a carreteras tienen exactamente la misma mediana en las dos clases. La exposición humana explica dónde puede haber ignición a escala de país, pero no distingue qué día arde una celda concreta.

El hallazgo que más cambió el diseño es que el peligro es relativo a la climatología del sitio (figura 3). El FWI mediano de los días de incendio va de 3 en Asturias y Cantabria a 41 en Andalucía: no existe un umbral absoluto que valga para toda la Península, y un modelo entrenado con FWI crudo aprende sobre todo a distinguir el norte húmedo del sur seco. El mismo dato expresado como percentil frente a la climatología de la propia celda se concentra entre 72 y 92 en las ocho comunidades. De ahí que el FWI entre tres veces —absoluto, en percentil local y en anomalía tipificada— y no una.




Figura 3: El peligro es relativo a la climatología local. Días de incendio del tramo de entrenamiento, por comunidad autónoma. (a) El FWI absoluto no admite un umbral común. (b) El percentil local de esos mismos días es alto en todas partes. Es el argumento de `fwi_pctl_local`.

La exploración dejó también un aviso para la interpretación posterior. Seis pares de variables superan $|\rho| = 0,8$ —`fwi` con `vpd_max` (0,86) y con `rh_min` (−0,81), `fwi_pctl_local` con `fwi_anom_sigma` (0,96), `ndvi` con `lai` (0,90)—, de modo que la importancia por ganancia se reparte entre variables que dicen casi lo mismo. No se eliminó ninguna, porque los árboles toleran la colinealidad y cada una aporta en zonas distintas del espacio, pero cualquier lectura de la importancia tiene que hacerse por bloques y no variable a variable.

1.4 Del problema al modelo

El problema se formula como clasificación binaria sobre el par (celda de 1 km, día), y en servicio se puntúan las 498.530 celdas del día y se ordenan. La formulación no dice nada sobre cómo construir el conjunto de entrenamiento, y ahí es donde se decide de verdad qué pregunta aprende el modelo.

La primera iteración adoptó el diseño habitual en la literatura de susceptibilidad, caso-control con la celda fija: cada ignición EGIF es un positivo y sus pseudo-ausencias se sortean en la misma celda en otros días del mismo bloque temporal, tres por positivo, excluyendo los días con fuego a menos de 12,5 km en ± 10 días. El clasificador es XGBoost con parada temprana a 100 rondas, hasta 3.000 árboles de profundidad 6, tasa 0,05 y semilla 42, sobre partición temporal sin solape. Obtiene 0,8906 [0,8644, 0,9136] en test 2022 frente al 0,7528 del FWI en percentil. El modelo que se puso en producción no es exactamente éste: es la misma receta reentrenada el 15 de julio de 2026 sin cuatro de sus 50 variables —los recuentos históricos de fuegos de la propia celda a 1 y 10 km— después de comprobar que el muestreo en la misma celda les colaba el orden temporal: el incendio del positivo entraba en el historial de los negativos posteriores de su celda, y el modelo aprendía que «historial vacío» significaba «antes del fuego», hasta el punto de subir el riesgo del centro de Madrid. Quitarlas costó −0,015 de AUC-PR (0,828 frente a 0,843) y dejó el modelo servido en 46 variables¹. Fue el primer aviso, aún sin entenderlo del todo, de que el diseño de los negativos se estaba colando dentro del modelo.

¹La verificación sobre los artefactos está en `03_iteracion1/33_train/verificar_v2.py`: el modelo de 50 variables y el servido difieren exactamente en esas cuatro. La bitácora de la iteración 1 (`MODELO_B_BITACORA.md`, §16) recoge el diagnóstico.

La figura 4 muestra la primera señal, visible en el propio conjunto de entrenamiento: el FWI en percentil local separa las clases con holgura —mediana 84,3 en positivos frente a 47,0 en negativos— mientras la densidad de población y la distancia a carreteras tienen exactamente la misma mediana en las dos. En un diseño de celda fija el positivo y su negativo comparten celda, así que todo lo estático se cancela por construcción, y el 98,8 % de las celdas del conjunto tenía exactamente un 25 % de positivos. El modelo no podía aprender qué celda es más peligrosa que otra; solo qué día lo es.




Figura 4: Medianas de las variables discriminantes en el conjunto de entrenamiento de la iteración 1 (53.563 filas, 13.577 positivos), reescaladas al mayor valor de las dos clases para poder dibujarlas juntas; a la derecha, los valores sin reescalar (positivos / negativos). En las dos últimas filas los dos puntos coinciden exactamente: el muestreo con celda fija cancela toda la información estática del territorio.

La figura 5 cierra el diagnóstico. Dos modelos idénticos en variables e hiperparámetros, que solo difieren en el diseño de los negativos, resultan indistinguibles en el banco caso-control de la iteración 1 —0,922 y 0,916, del orden del ruido del sorteo— y se separan 0,082 en el banco operativo, donde gana el entrenado con negativos del mismo día: la métrica de desarrollo no podía ver la diferencia que más importaba. Antes se habían agotado las explicaciones más cómodas, todas medidas y todas negativas: reajustar con más años, rehacer la etiqueta con el EGIF consolidado (−0,0012), entrenar un modelo nativo de estación, servir con ERA5-Land nativo y congelar las variables de satélite para reproducir el desajuste con el servicio (−0,0041). Ninguna cierra un hueco de veinticinco centésimas.




Figura 5: La misma pareja de modelos —mismas 46 variables, mismos hiperparámetros, distinto diseño de negativos— bajo dos métricas. A la izquierda, AUC en el banco caso-control de cada diseño: indistinguibles. A la derecha, AUC dentro del día en el banco operativo (test 2020, verdad EGIF): se separan 0,082. Un buen número en la métrica de desarrollo no garantiza nada sobre la pregunta operativa si el muestreo no la reproduce.

La segunda iteración cambia las dos cosas que el diagnóstico señalaba. La etiqueta pasa a ser EFFIS, la misma con la que se valida en operación, tomando como positivo el primer día de cada celda quemada con un tope de 30 por día y bloque de 100 km, para que un solo megaincendio no sea la mitad del conjunto; y los negativos pasan a sortearse el mismo día, en otra celda cualquiera. La figura 6 contrapone los dos diseños y el banco de evaluación sobre la misma rejilla, y la tabla 1 resume las dos iteraciones. Los hiperparámetros se heredan sin retoque, de forma deliberada: solo así la diferencia medida es atribuible al diseño. Se comparan dos

arquitecturas —un modelo único sobre el diseño del mismo día y la pareja dónde×cuándo del encargo original— y se ablaciona el ratio de negativos, heredado como 1:3 sin justificación.




Figura 6: Los tres diseños de muestreo sobre la misma rejilla de celdas y días. En a) el caso-control fija la celda y varía el día, de modo que todo lo estático se cancela; en b) el diseño del mismo día fija el día y varía la celda, que es la comparación que hace el usuario del mapa; en c) el banco de evaluación enfrenta las celdas quemadas del día contra 1.000 celdas sorteadas de ese mismo día. Los tres se construyen con los mismos datos y dan modelos muy distintos.

Sobre el control de la fuga de información conviene ser explícito, porque hubo una. Además de la regla de ventanas estrictas, se auditó cada variable comparando su desplazamiento en la celda que arde el día D contra un anillo de control. Tres de las 46 —NDVI, temperatura de superficie y humedad superficial— resultaron concurrentes: el satélite ya ve la firma del incendio el mismo día. La prueba está automatizada en `dos_24_auditoria_fugas.py` y acompaña a esta memoria en el repositorio, igual que la comprobación de desfase de `dos_23_vispera.py`. Pesan el 4,6 % de la importancia del modelo único y no sesgan la comparación, porque ambas iteraciones comparten receta, pero inflan los valores absolutos de toda evaluación del mismo día. Se detectó además que la interfaz de FIRMS cuenta los cinco días hacia adelante desde la fecha pedida y no hacia atrás, con lo que el mapa retrospectivo del día D llevaba dentro los focos del propio incendio; entrenamiento y producción estaban limpios, y la evaluación retrospectiva se relanzó entera. El arreglo refuerza la conclusión: la ventaja del rediseño pasa de +0,037, rozando el cero, a +0,105.

	Iteración 1 (grupo de control)	Iteración 2 (rediseño)
Etiqueta	EGIF, ignición puntual, 2015–2020	EFFIS <code>is_fire</code> , celda quemada ≥ 5 ha, primer día
Negativos	misma celda, otro día; 1:3; buffer 12,5 km y ± 10 días	mismo día, otra celda; ratio ablacionado de 1:3 a 1:100
Partición	train 2015–2020 / val 2021 / test 2022	train 2015–2022 / val 2023 / test 2024 / externo 2026
Variables	50 en entrenamiento; 46 en el modelo servido	46 (las del servido)
Métrica de desarrollo	AUC-ROC caso-control 0,8906 [0,8644, 0,9136]	AUC-PR en validación de 0,950 (1:3) a 0,737 (1:100)
Métrica operativa (2026)	AUC dentro del día 0,647	0,752 (1:3) y 0,759 (1:10)

Tabla 1: Las dos iteraciones lado a lado. La comparación es del diseño del conjunto de entrenamiento: fuentes, variables, hiperparámetros y semillas son idénticos, y la partición cambia solo porque EFFIS cubre años que EGIF no cubre.

1.5 Evaluación

La métrica principal es el AUC-ROC calculado dentro de cada día: para cada día con al menos un positivo se enfrentan las celdas quemadas de ese día contra 1.000 celdas sorteadas del mismo día, y se promedia sobre días. Reproduce la decisión operativa —ordenar las celdas de hoy, no comparar hoy con otro día—, mientras que un AUC global premia sobre todo acertar qué días son peligrosos, que es información que el usuario ya tiene. Y el desbalanceo obliga: con una prevalencia del orden de cinco celdas por cada 100.000 y día, toda métrica de umbral fijo es inutilizable y el AUC-PR global queda dominado por los pocos días de megaincendio. Como complemento se reportan el lift del decil superior, el percentil —también ponderado por hectáreas— en que cae la celda quemada, y la cobertura de superficie quemada dentro del 2 % mejor puntuado. Los intervalos salen de un bootstrap de 2.000 remuestreos de días completos, nunca de celdas.

Las líneas base son el FWI en percentil local, un mapa estático de susceptibilidad y, sobre todo, el modelo de producción, que es lo que hoy se sirve. En el test interno de 2024 la ventaja del modelo único todavía no es concluyente: 0,809 frente a 0,792, intervalo $[-0,024, +0,063]$, con el FWI en 0,636 y la pareja dónde×cuándo en 0,762. Es la temporada 2026, con 74 días, 4.843 celdas quemadas y 260.753 hectáreas, la que resuelve:

producción 0,647, modelo único 0,752 (+0,105 [+0,067, +0,146], 70 % de días ganados) y el mismo modelo con ratio 1:10 en 0,759 (+0,112 [+0,074, +0,151], 76 %). La pareja queda en 0,705. La figura 7 muestra la serie y la trayectoria del intervalo.




Figura 7: Temporada 2026, del 1 de junio al 15 de agosto. Arriba, AUC dentro del día: la línea fina es el valor diario —ruidoso, porque un día con tres celdas quemadas no dice nada— y la gruesa su media acumulada. Abajo, la diferencia pareada acumulada contra producción con su intervalo al 95 % por bootstrap de días. El número que se defiende es el del último día, fijado de antemano al cierre de la temporada; leer la banda cada día y cantar victoria el primero en que despega del cero sería *peeking* sobre 74 miradas.

Las ablaciones acotan de dónde sale la ventaja. El ratio de negativos tiene un óptimo interior: la escalera 1:3, 1:10, 1:30, 1:60 y 1:100 da en 2026 valores de 0,748, 0,759, 0,753, 0,748 y 0,745. Esa ganancia es del orden del ruido de volver a sortear los negativos con la misma receta, medido en 0,004; lo que sí mejora es el fuego grande, con el percentil ponderado por hectáreas subiendo de 76,2 en producción a 79,8 en el modelo único y 81,9 en la variante 1:10. Entrenar solo con los meses de verano empeora (−0,028), y añadir una capa que apague el riesgo en lo ya quemado también (−0,021), coherente con la etiqueta: EFFIS marca días ardiendo y penaliza bajar el riesgo de un perímetro activo. Los focos FIRMS aportan menos de lo que se creía, +0,036, sin llegar a la punta del ranking.

El análisis de error se resume en la figura 8. El modelo único concentra el 29,2 % de su importancia en una sola variable, la densidad histórica de incendios a 10 km en el mismo mes, seguida de los usos del suelo CORINE (14,3 %) y la pendiente (5,8 %); producción reparte su peso sobre la meteorología, con el 20,5 % en la anomalía tipificada del FWI. Al cambiar el muestreo, el modelo deja de aprender el cuándo y empieza a aprender el dónde. El precio está en el panel derecho: el modelo único pierde muy poco acierto cuando se le desplaza el mapa uno, dos o tres días respecto al día del fuego, mientras producción pierde de forma clara. Un mapa que no pierde nada al alejarse del suceso se apoya en lo persistente —el territorio— y no en la ignición concreta: ahí está el límite del sistema y el sitio por donde tiene que crecer. La misma comprobación, leída al revés, es la que destapó la fuga de FIRMS: si el acierto no decae al alejar el predictor del suceso, algo está viendo el suceso.




Figura 8: Izquierda: importancia por *gain* de los dos modelos sobre las nueve variables más pesadas. Derecha: porcentaje de hectáreas quemadas del día que caen dentro del 2 % de celdas de mayor riesgo, según los días de desfase entre el mapa y el fuego. El mapa estático es plano por construcción y el FWI se desploma; entre esos dos extremos, cuanto más plana es la curva, más se apoya el modelo en el territorio y menos en el día concreto.

1.6 De la ordenación a la probabilidad

Todo lo anterior mide capacidad de *ordenar*: el AUC no cambia si se aplica una transformación monótona a la puntuación. Un mapa operativo, en cambio, no se lee como un orden. El sistema en producción pinta cuatro niveles con los percentiles del día —`CORTES_PCTL` = [30, 90, 98]—, de modo que el 2 % superior aparece en rojo *todos los días por construcción*: un martes de febrero recibe tanto rojo como el 15 de agosto. Bajo ese mismo color, la puntuación absoluta del percentil 98 de un día de invierno varía entre 0,032 y 0,965. El color, tal como está definido, no informa de nada.

Para atacarlo se puntuaron los cinco modelos sobre los 3.653 días de 2015–2024 del cubo, guardando un histograma diario de 4.096 clases por modelo y la puntuación exacta de las 64.088 celdas-día que ardieron. La partición se fija en calibración 2015–2021, validación 2022–2023 y prueba 2024, y el umbral se elige únicamente en calibración.

Dos regímenes de incendio, no uno

La primera comprobación desmiente la premisa de partida. La estacionalidad española no es un verano peligroso y un invierno inerte: entre noviembre y marzo hay fuego el 33,9 % de los días, y marzo —con 149 días de 310— se acerca a septiembre. La diferencia es *dónde*. En diciembre-abril, el 85,6 % de las celdas quemadas cae en el noroeste peninsular (Galicia, Asturias, Cantabria, León y Zamora), que es el 14,4 % del territorio; en junio-septiembre, el 40,7 %. Es la temporada de quemas pastorales, gobernada por la ignición y no por la sequía. La estadística oficial del EGIF lo corrobora por una vía independiente: marzo es el mes con más incendios del año, 10.471 entre 2008 y 2024, por delante de agosto (6.170).

El aviso de día funciona en invierno y no en verano

Definido el objetivo como día grande —al menos cinco celdas de primer día, es decir unas 500 ha—, y calibrada la probabilidad con el método beta de Kull et al. (2017) por régimen, la habilidad se separa de forma nítida (Tabla 2). En invierno-primavera los cinco modelos superan a la climatología del día del año con intervalo que excluye el cero; en verano los cinco intervalos lo cruzan. La lectura correcta no es que el aviso sea peor en verano, sino que *no se distingue* de la estacionalidad: en julio ya se sabe que es día de riesgo sin necesidad de modelo.

Un solo umbral sirve para todo el año: los umbrales estimados por régimen se separan entre un 8 y un 18 % en la escala de puntuación, y el umbral único iguala o mejora al específico en ocho de los diez casos de prueba. Los dos regímenes se distinguen en *dónde* arde y en la frecuencia base, no en el nivel de puntuación que hay que exigir.

Tabla 2: Aviso de día, prueba 2024. BSS contra la climatología del día del año e índice SEDI, con intervalo al 95 % por remuestreo.

Régimen	Modelo	BSS [IC 95 %]	SEDI
Invierno-primavera	producción	+0,258 [+0,189, +0,328]	0,815
Invierno-primavera	único 1:10	+0,297 [+0,198, +0,381]	0,794
Invierno-primavera	pareja	+0,181 [+0,109, +0,255]	0,764
Verano	producción	−0,076 [−0,183, +0,032]	0,506
Verano	único 1:10	−0,107 [−0,230, +0,022]	0,368
Verano	pareja	−0,086 [−0,207, +0,034]	0,399

Qué significa el rojo

Sustituyendo los percentiles del día por cortes leídos de la distribución climatológica de 2015–2024, el color adquiere por fin un contenido medible (Tabla 3). El nivel extremo corresponde a una probabilidad de quema de 0,126 % —una celda de cada ochocientas—, treinta y seis veces la frecuencia base; y el nivel bajo, que cubre el 30 % del territorio, acumuló cinco celdas quemadas en diez años. Calibrada la probabilidad por celda con regresión isotónica sobre el censo completo, la celda peor clasificada que llega a existir en toda la serie no supera el 1,6 %. Es, por tanto, un instrumento de vigilancia y priorización, no un pronóstico de que una celda vaya a arder.

Tabla 3: Significado de cada nivel con cortes absolutos, modelo único 1:10. Frecuencia observada de quema sobre 365 millones de celdas-día.

Nivel	% territorio	Celdas quemadas	Frecuencia	Factor
Bajo	30,1	5	0,0000 %	0,0
Moderado	59,9	1.062	0,0005 %	0,1
Alto	8,0	2.682	0,0092 %	2,6
Extremo	2,0	9.148	0,1259 %	35,6

La escala absoluta, sin embargo, no basta por sí sola. Con ella, el modelo único no tiene *ni un solo día sin rojo* en diez años: la componente de dónde está dominada por variables estáticas —usos del suelo, historia de fuego, pendiente— y las mismas celdas superan el corte en enero y en agosto. El mapa no puede apagarse solo. Encadenándolo al aviso de día, en cambio, el 44 % de las jornadas de invierno quedan sin nivel extremo perdiendo únicamente el 6,2 % de los días grandes. La arquitectura en dos capas deja de ser una preferencia de diseño y pasa a ser una necesidad demostrada.

Dos resultados negativos

El primero acota qué se puede publicar. La punta del ranking varía mucho con el mes —del 0,28 % en diciembre al 10,36 % en julio, un factor 37— y una calibración estratificada por mes la sigue con un error típico de 1,8 veces, frente a 2,4 de una curva única. Pero calibrar con los años inmediatamente anteriores en lugar de con toda la historia, que parecía el remedio natural, *empeora* el resultado de forma monótona: en junio-septiembre el error pasa de 0,45 usando toda la serie a 0,95 usando tres años. La razón es que la frecuencia observada en la punta de julio oscila entre el 0,00 % de 2023 y el 12,76 % de 2022, con mediana 0,53 %, y esa variación no reside en la puntuación de la celda sino en la intensidad de la temporada. Se probaron tres remedios —estratificar por mes, acortar la ventana y descomponer en el producto $P(\text{día grande}) \times P(\text{celda} \mid \text{día grande})$ — y los tres fallan por la misma razón: condicionada a día grande, la punta de julio de 2022 alcanza el 14,95 % frente a un máximo de 2,05 % en los años de calibración, siete veces por encima. No es un problema de esquema de calibración sino de extrapolación. Lo que se sostiene es que la probabilidad por celda está bien calibrada en condiciones típicas —contra la mediana de julio, 0,53 %, el modelo dice en torno al 0,9 %— y que en una temporada de récord se queda corta en un orden de magnitud; declararlo es más útil que ocultarlo.

El segundo cierra una duda razonable sobre la partición. El modelo servido se entrena con 2015–2022 y reserva 2023 y 2024, de modo que ignora dos años de datos. Reentrenado con la serie completa —un 32 % más de positivos— y medido sobre las 224 jornadas de 2025 y 2026 reconstruidas con previsión archivada, la ganancia es de +0,0033 de AUC con intervalo [−0,0042, +0,0104]: indistinguible de cero, y gana el 54,5 % de los días. El experimento se registró antes de ejecutarse, y su validez descansa en dos controles: la réplica del modelo servido lo reproduce con diferencia máxima nula, y los cuatro modelos no modificados devuelven las mismas cifras que la evaluación original en los 224 días. La conclusión es que el modelo está saturado de datos y que la partición actual, que conserva una prueba honesta reservada, no cuesta rendimiento. Para situarlo: la distancia entre este modelo y producción (+0,079) es veinticuatro veces mayor que lo que aporta reentrenar con todo.

1.7 Limitaciones y trabajo posterior

La limitación de fondo es que la ventaja se demuestra en evaluación retrospectiva, con reanálisis meteorológico para todos los modelos: es un cara a cara limpio, pero una cota superior de lo que dará la operación, donde se trabaja con previsión. La única comparación sin retrovisor para nadie son 19 días de julio y agosto de 2026 contra el ranking sellado que se publicó ese mismo día: por estación meteorológica el modelo único obtiene 0,605 frente a 0,568 y gana 14 de los 19 días, pero con intervalo $[-0,020, +0,085]$; por celda la diferencia sí es concluyente, 0,755 frente a 0,669 $[+0,022, +0,156]$.

Tres limitaciones más, todas asumidas. Las variables concurrentes ya mencionadas inflan los valores absolutos de toda evaluación del mismo día, aunque no la comparación. El modelo se entrenó con una ventana de focos FIRMS de siete días mientras la tubería de servicio pedía cinco; corregirlo aporta +0,003, ruido, pero es un desajuste real que estuvo sin detectar. Y el repositorio que acompaña a esta memoria todavía no incluye un fichero de entorno con las versiones de las dependencias, de modo que ninguna cifra es reejecutable tal cual por un tercero: es el hueco más grave que queda abierto. Tampoco hay curva de precisión-exhaustividad ni análisis de calibración de la segunda iteración, que sí existen para la primera.

Dos incidencias de la operación quedan documentadas y, a propósito, sin corregir en la serie. La primera es un error en el ranking sellado de producción al combinar las dos fuentes de viento (`np.minimum` donde correspondía `np.fmin`), que hunde el FWI cuando una de ellas falta: afecta al 16,3 % de las estaciones-día y se conoce desde el 18 de agosto, pero se mantiene hasta el cierre para no romper la serie contra la que se miden los jueces, y se corrige después. La segunda es la pérdida, por un incidente de publicación de estado el 31 de agosto, de los cinco mapas diarios del 27 al 31 de agosto de 2026; reconstruirlos exigía unas 56.000 unidades de la API de previsión compitiendo con la cadena viva, y se decidió no hacerlo: esos cinco días no podrán puntuarse cuando lleguen sus perímetros EFFIS.

Ordenadas por relación entre valor y esfuerzo, las acciones siguientes son cuatro. La primera, cerrar el fichero de entorno y la ejecución de demostración: trabajo de horas, y lo que separa un repositorio legible de uno reproducible. La segunda, servir la variante con ratio 1:10, que ya está entrenada, publicada y recogida por los tres jueces en operación. La tercera, atacar el radio de 50 km de las variables FIRMS, la hipótesis viva para explicar por qué los focos activos no ayudan en la punta del ranking: un radio tan grueso arrastra la puntuación hacia lo que ya ha ardido en lugar de hacia la ignición nueva. La cuarta, ya como trabajo futuro, entrenar sobre previsiones en lugar de reanálisis, que es la única forma de cerrar la distancia entre la cifra retrospectiva y la operativa. Las tres primeras están preparadas en el repositorio; la cuarta no. El veredicto acumulado de los tres jueces se cierra a mediados de septiembre de 2026 y es el que decide.